Data Science
Bootcamp



WOMAKERS CODE

Host Oficial

sãojudas universidade

MÓDULO #4.0

Modelos de classificação

Priscilla Koch Wagner
Vivian Mayumi Yamassaki



Priscilla Koch Wagner

Cientista de Dados na BLU365

priscillaKW

priscilla-wagner



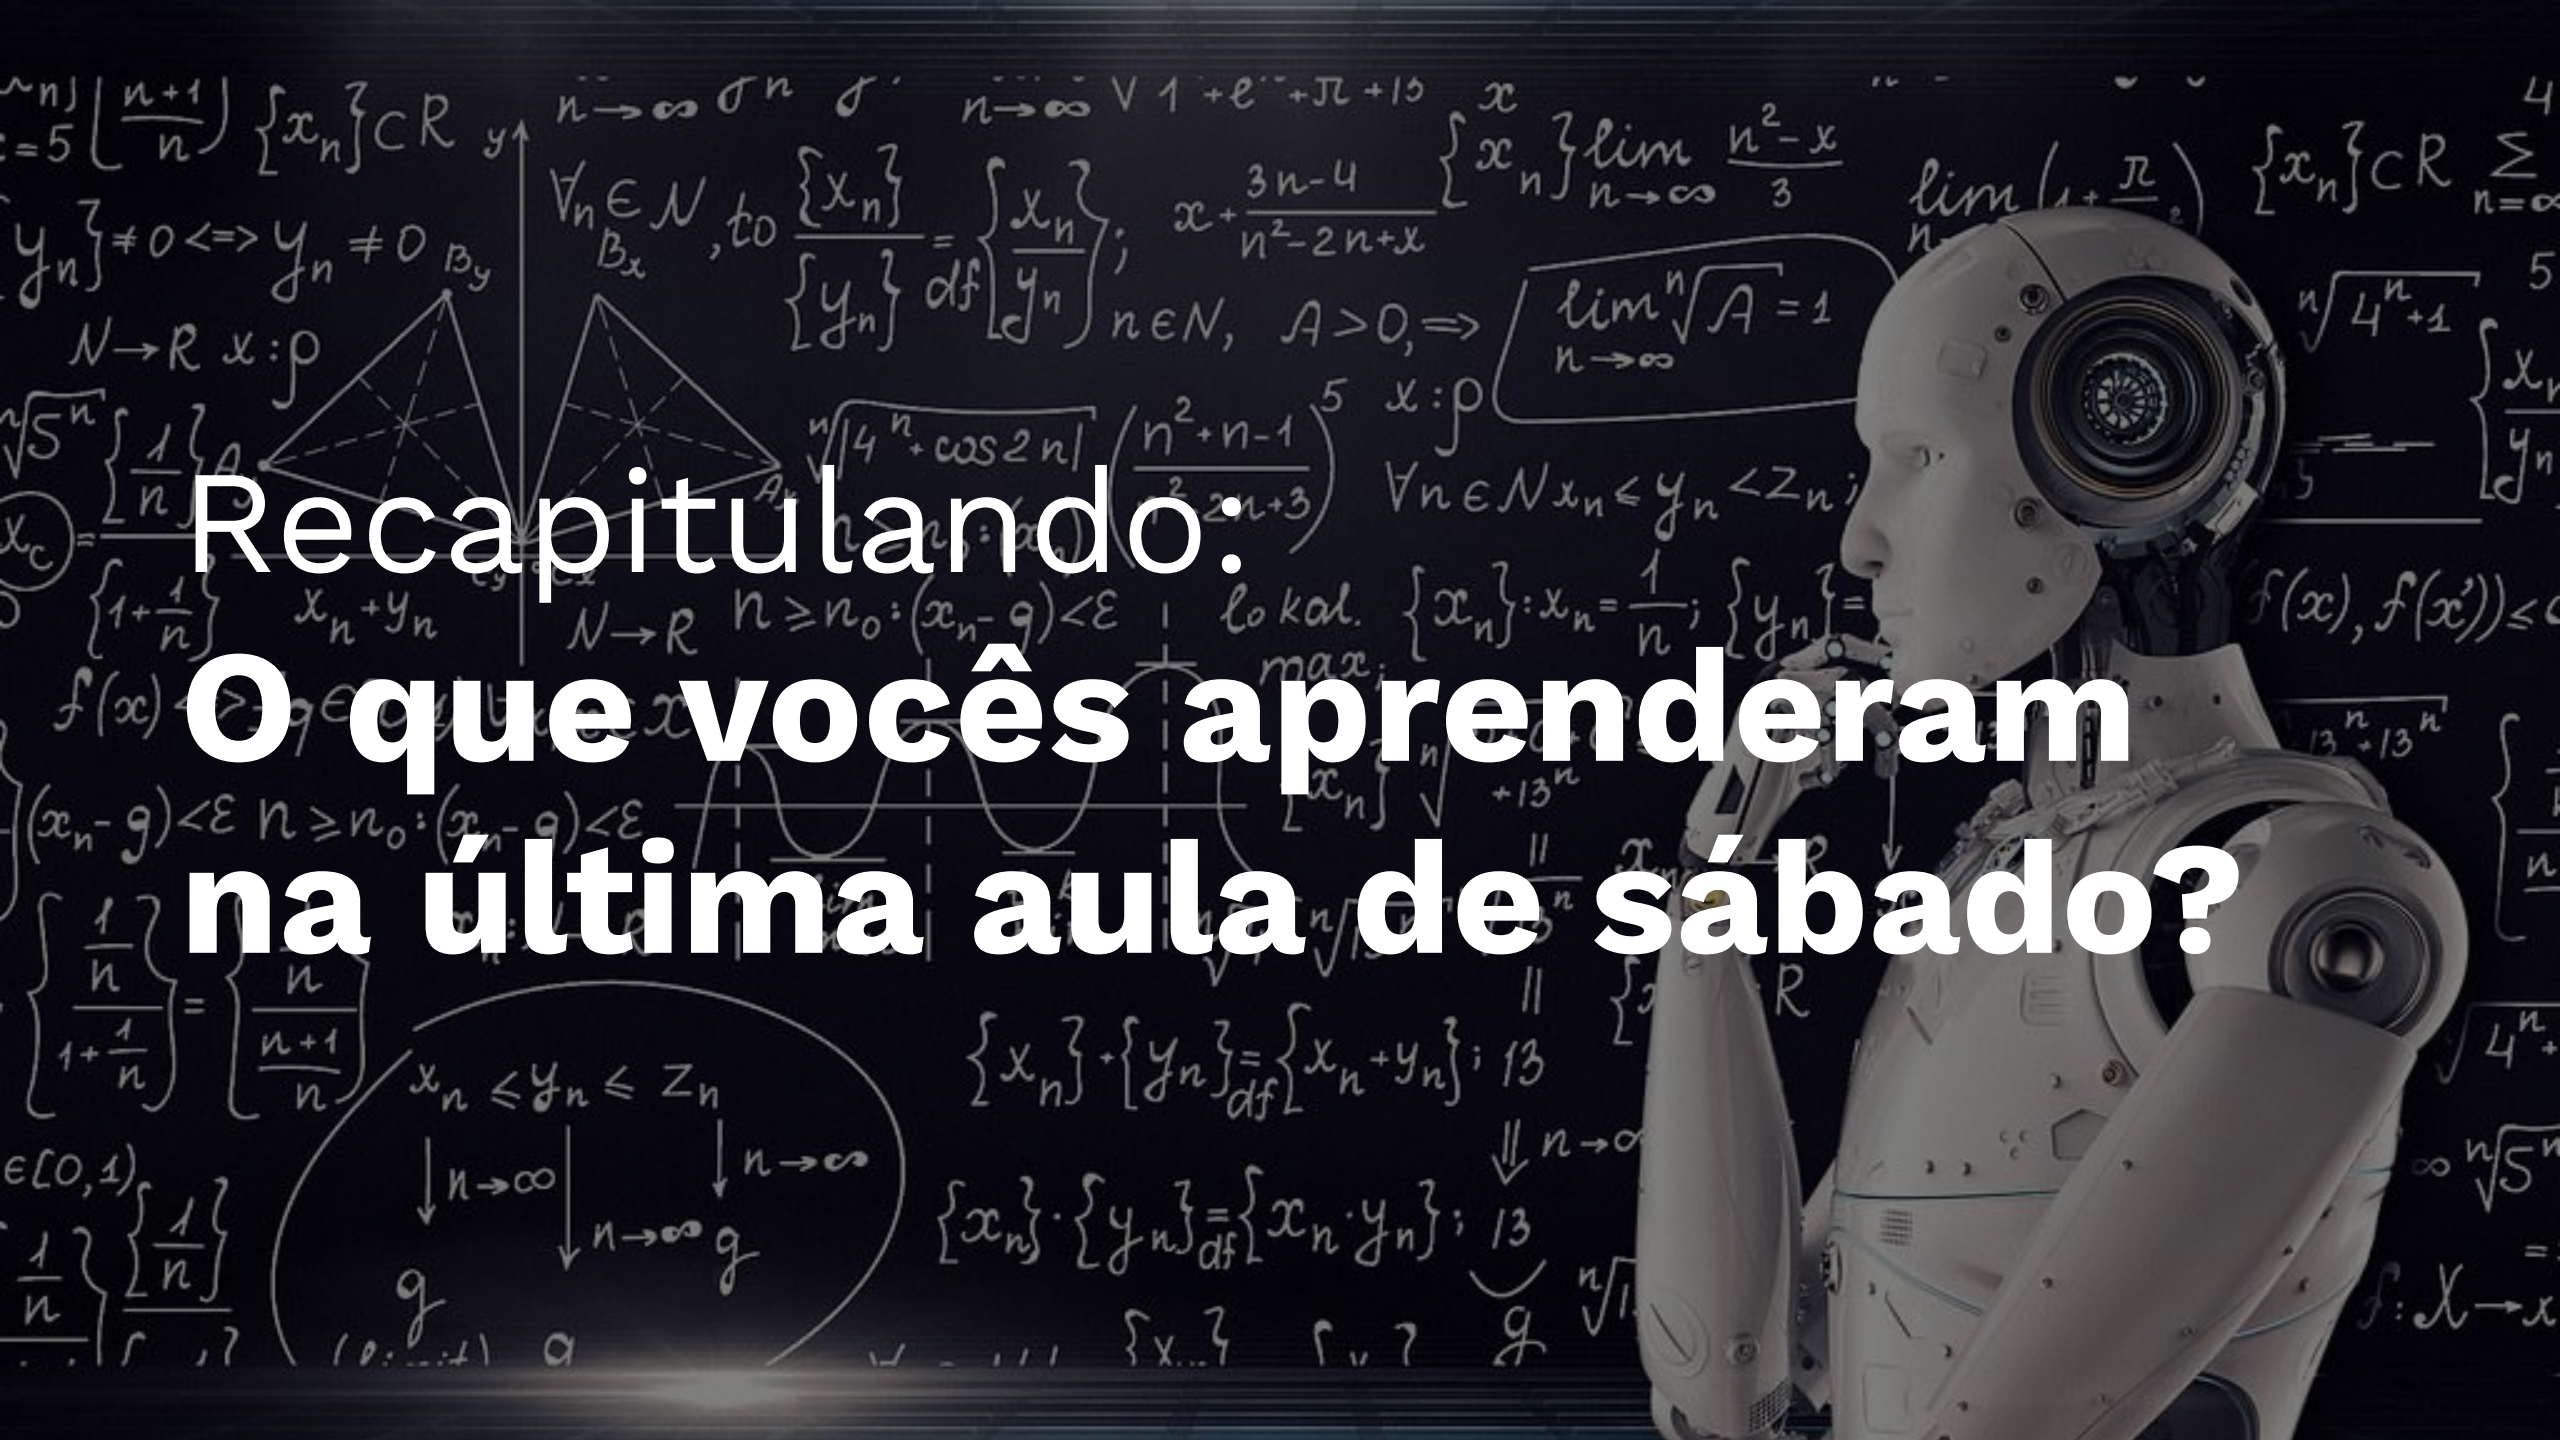
Vivian Mayumi Yamassaki

Cientista de Dados na Creditas

vivianyamassaki

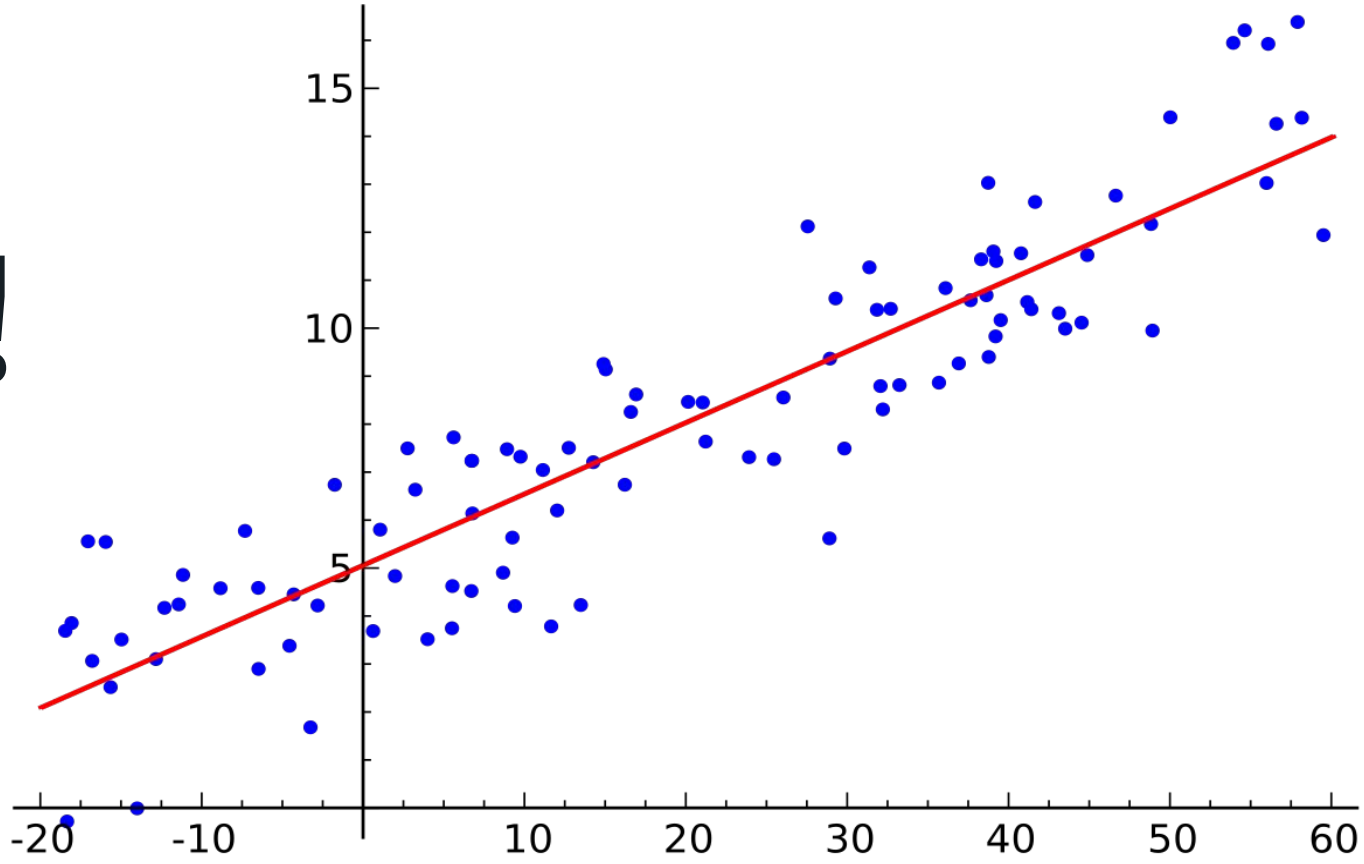
vivianyamassaki




Recapitulando:
O que vocês aprenderam na última aula de sábado?

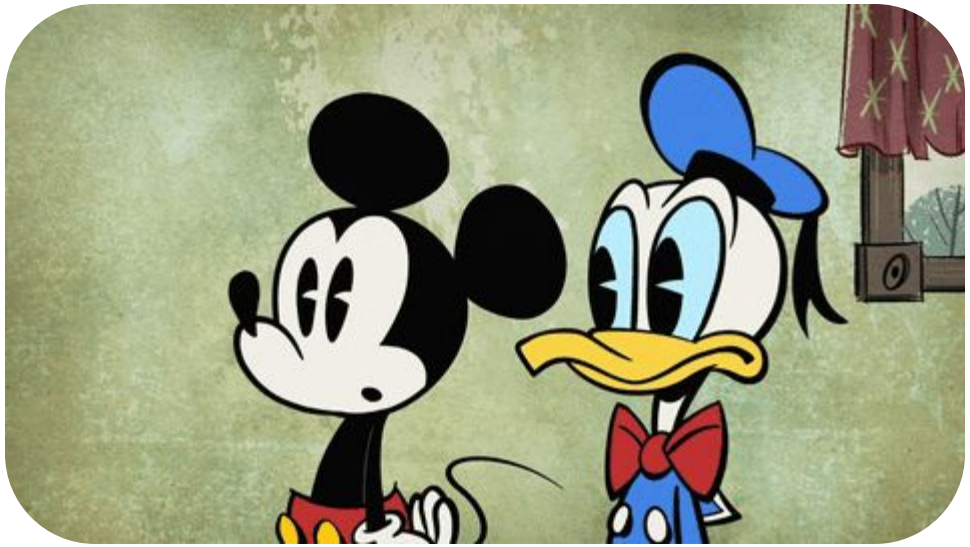
Regressão!

Em que situações vocês a usariam?



E se tivéssemos que predizer se um imóvel vai ser vendido ou não?

Poderíamos fazer uma regressão nesse caso?



Predizer se um imóvel será vendido ou não assim como predizer...

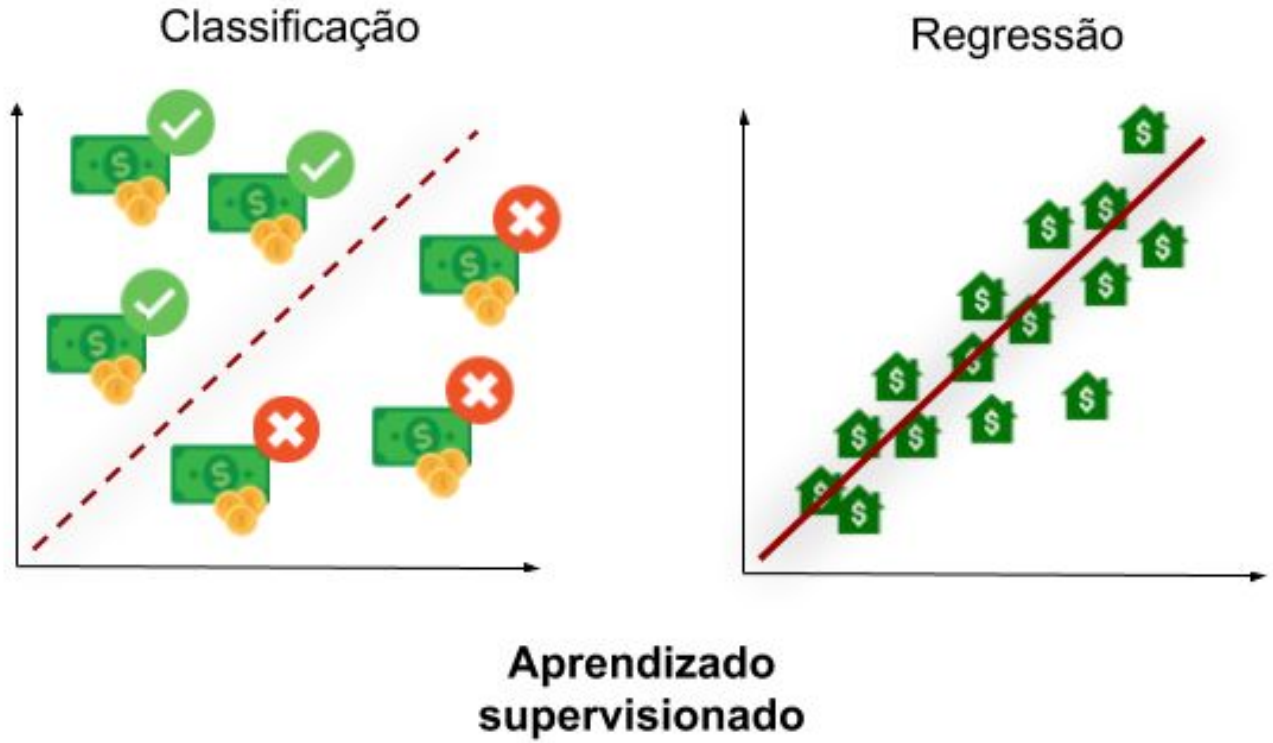
- se um e-mail é spam ou não
- a raça de um cachorro com base em uma foto



São problemas de

CLASSIFICAÇÃO!

Classificação vs regressão



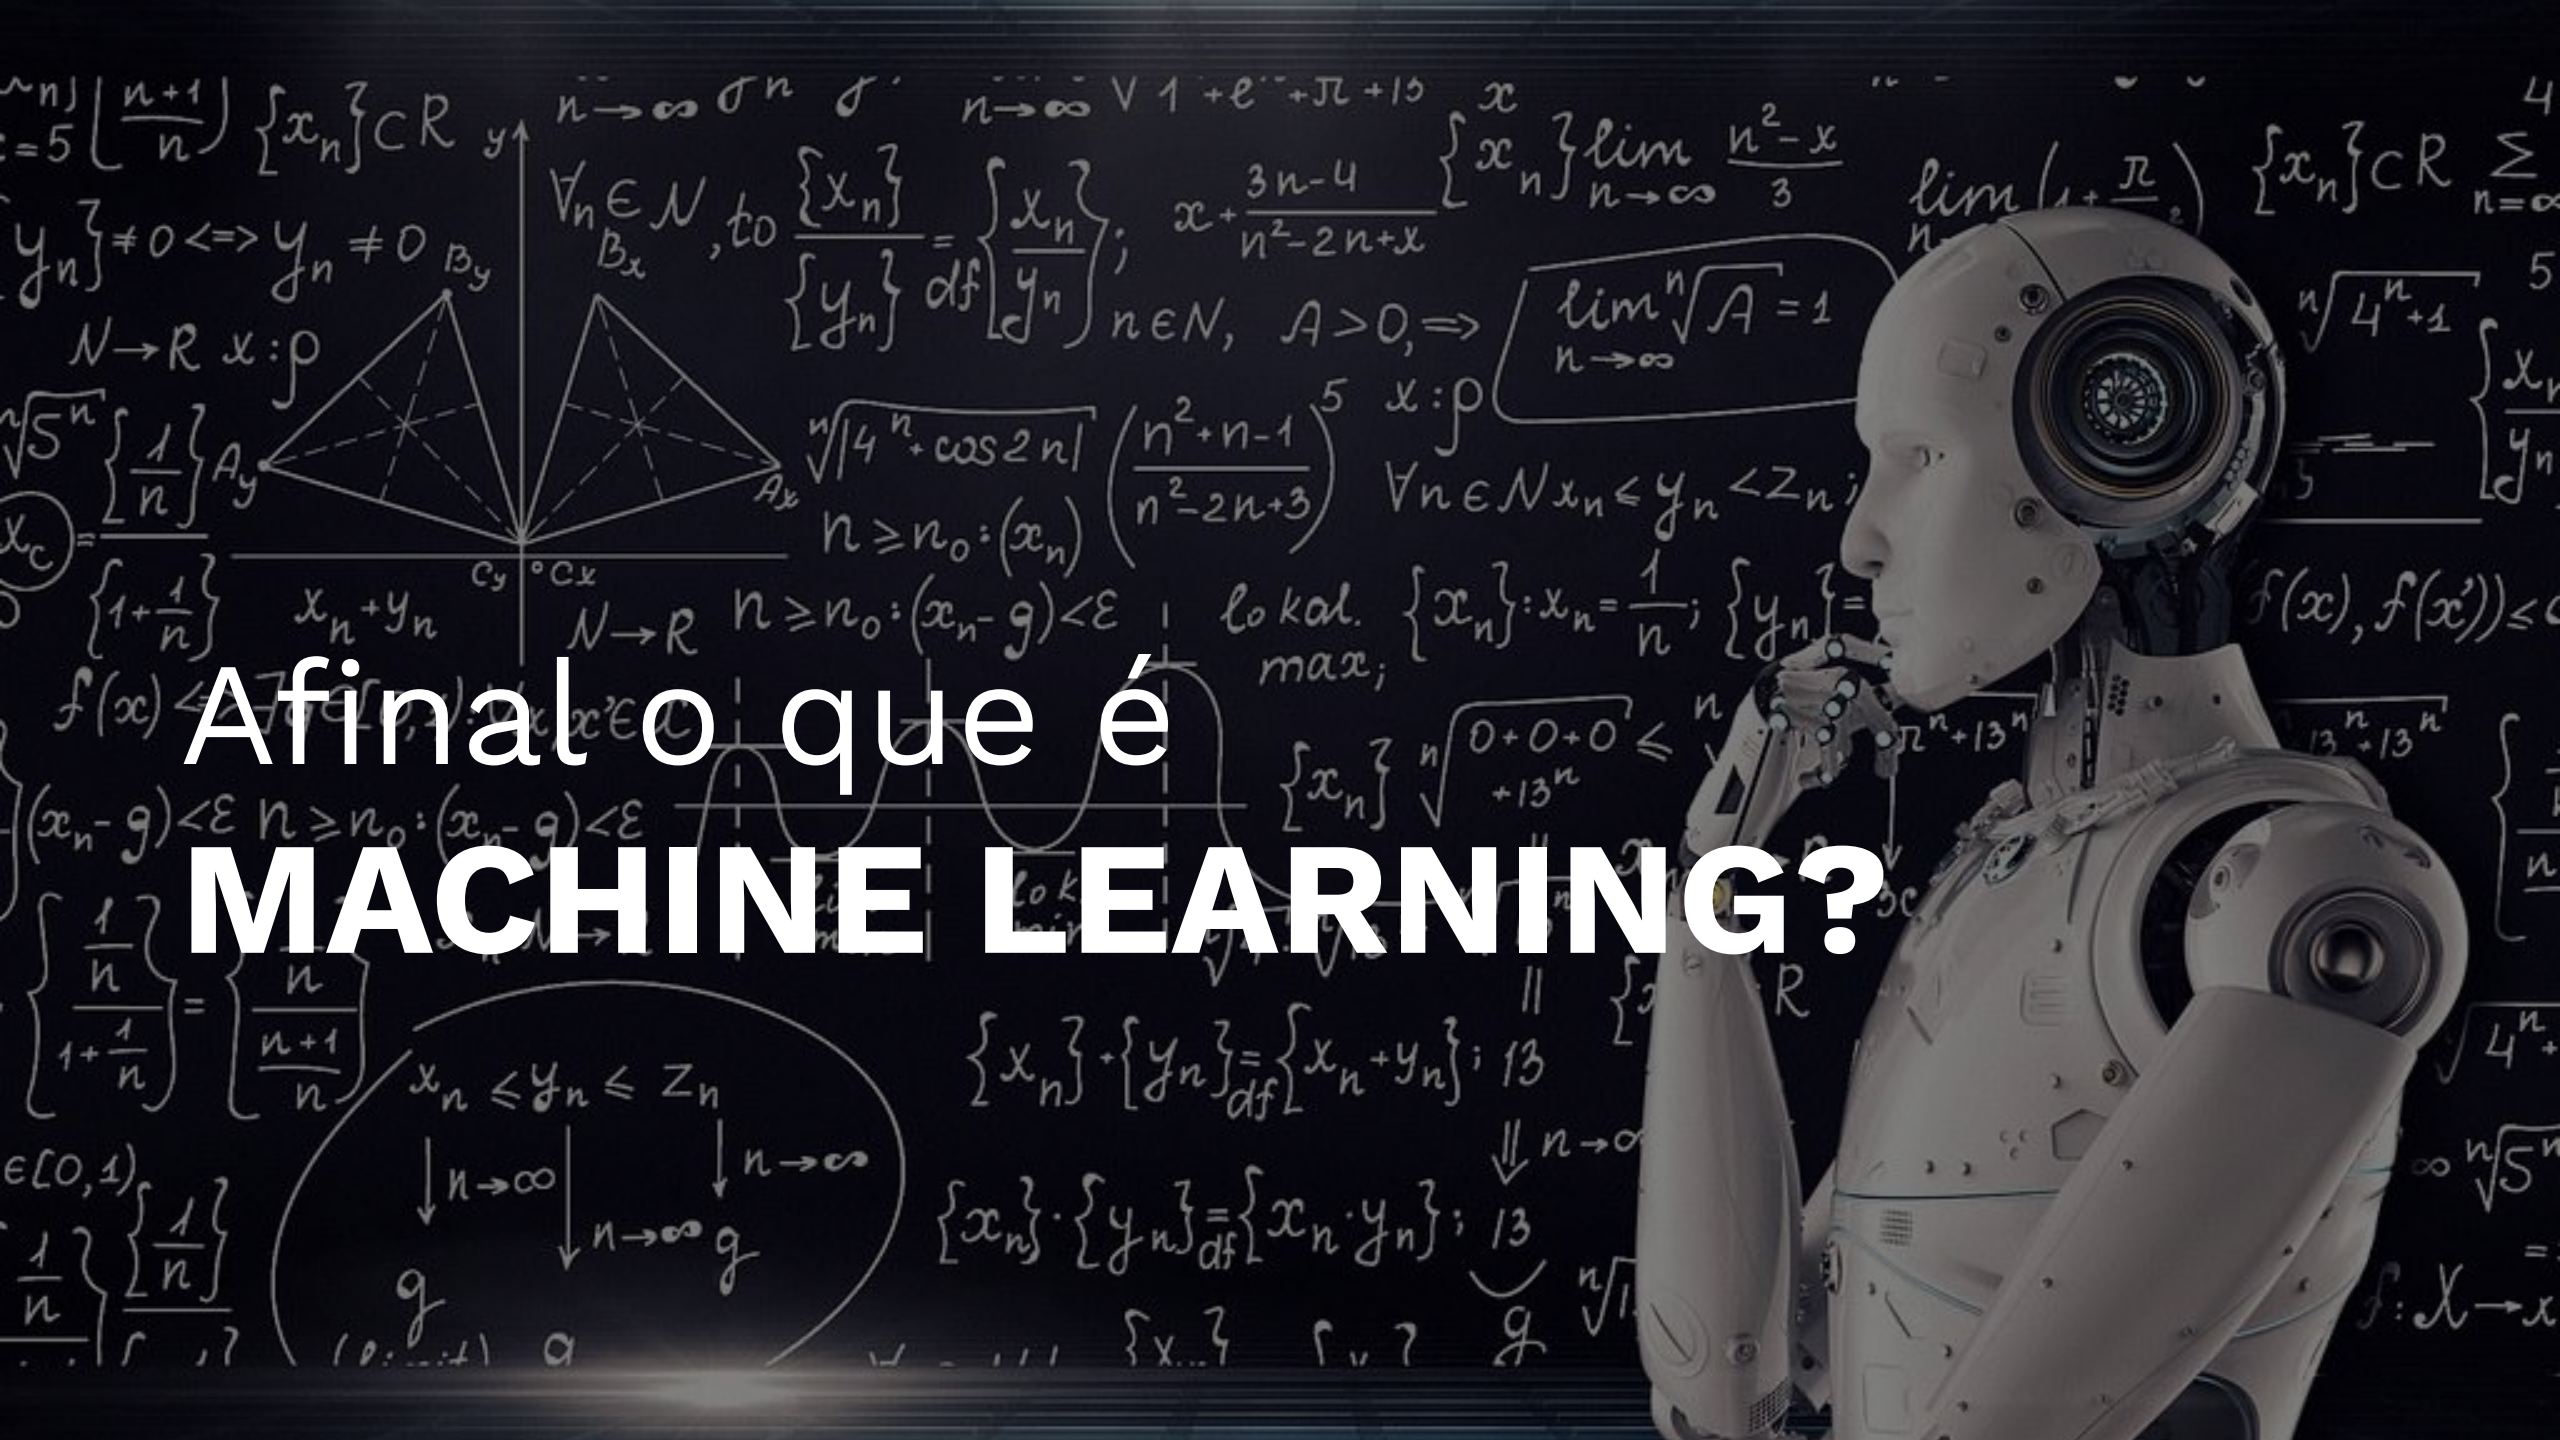
Classificação

Aprendizado supervisionado

Regressão



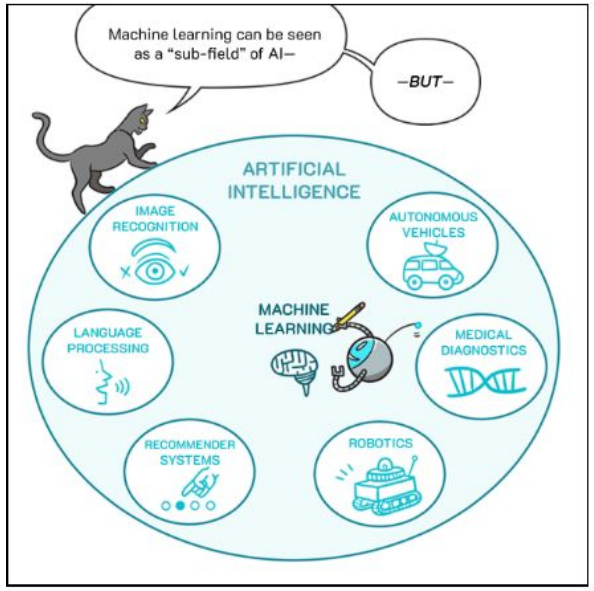
Machine Learning

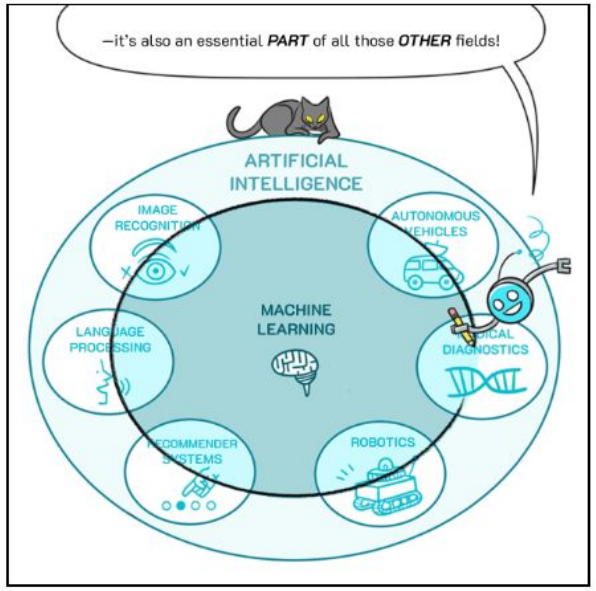

Afinal o que é
MACHINE LEARNING?

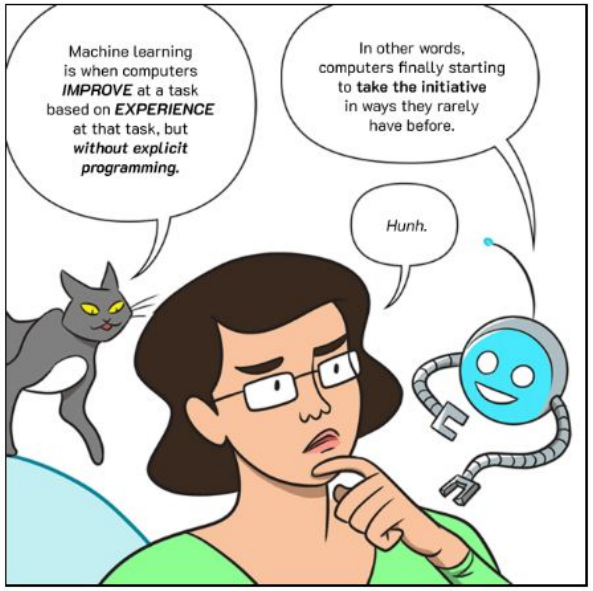
“Aprendizado de Máquina ou Machine Learning é um conjunto de regras e procedimentos, que permite que os computadores possam agir e tomar decisões baseados em dados ao invés de ser explicitamente programados para realizar uma determinada tarefa”

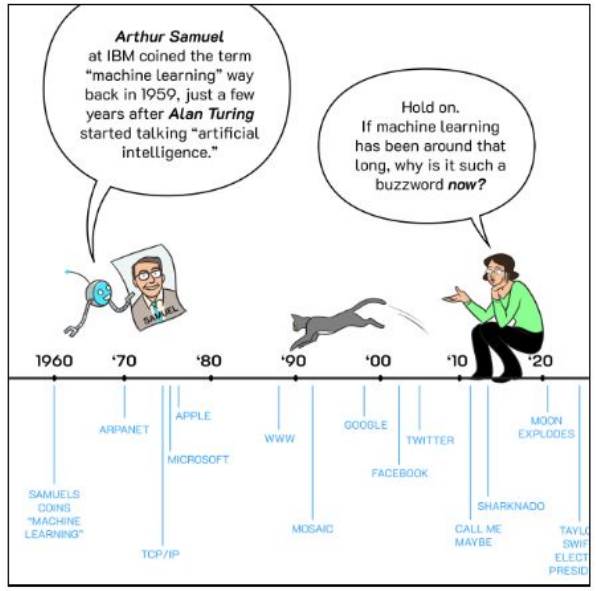


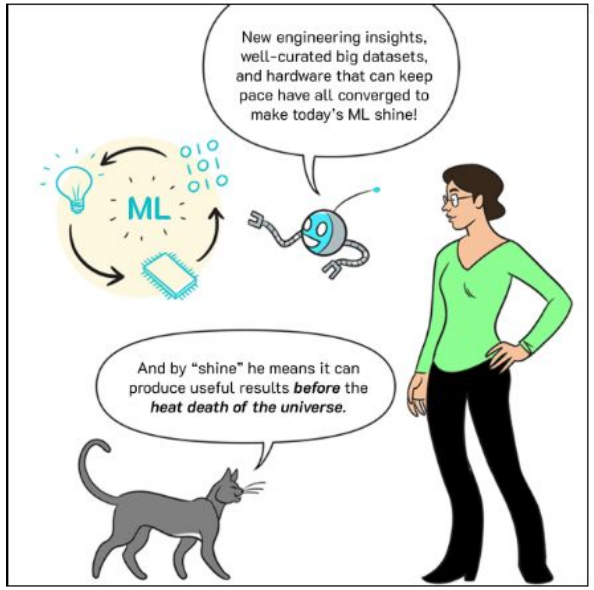
* Citação retirada daqui.







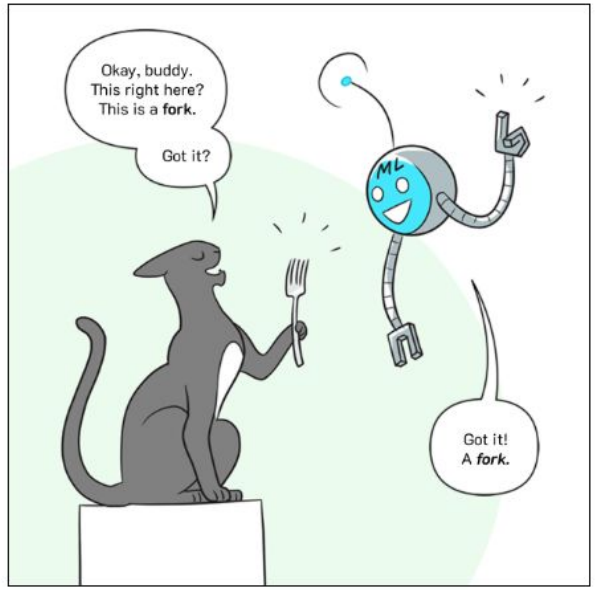






Machine Learning é alimentado por dados e não instruções





Aqui você consegue ver o quadrinho completo :)

Categorias

- Aprendizado Não-Supervisionado (em que não há labels):
  - Clusterização
- Aprendizado Supervisionado (em que há labels):
  - Classificação
  - Regressão

* há também o aprendizado semi-supervisionado (em que há alguns dados com labels e a maioria não, mas são métodos menos utilizados e que ainda estão surgindo) e o aprendizado por reforço (em que o programa tenta na verdade encontrar “caminhos”).



Aprendizado supervisionado vs não supervisionado

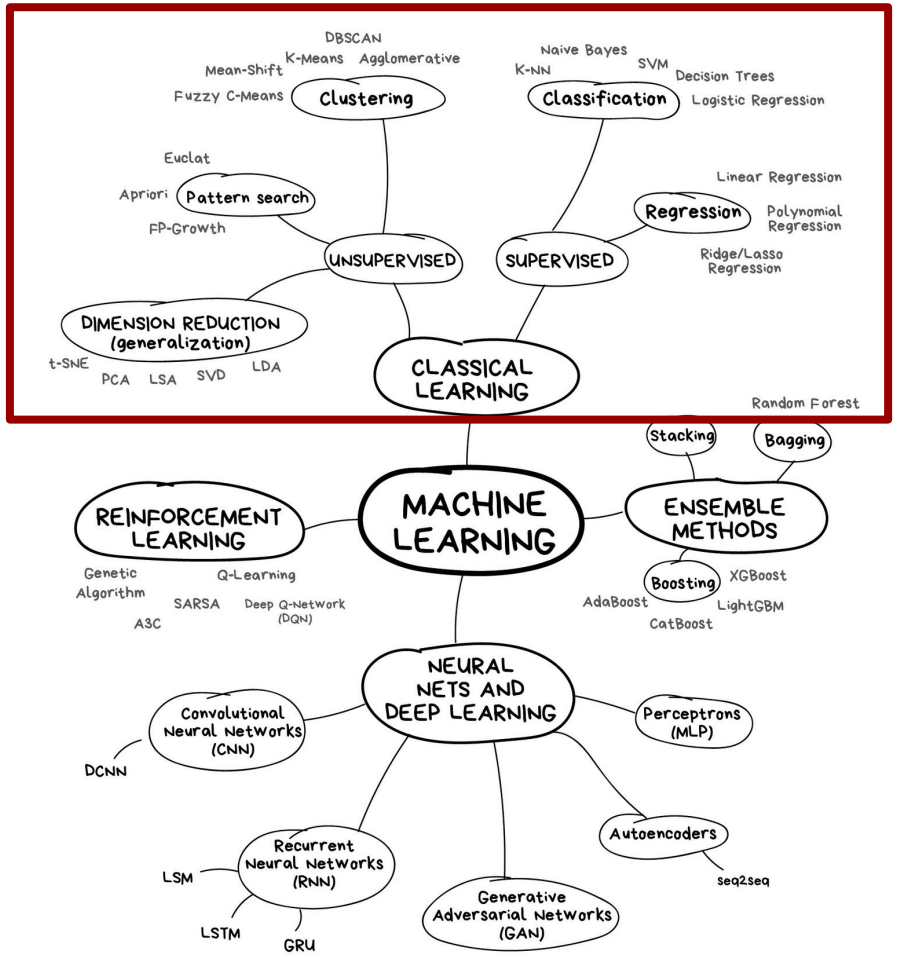


Diagrama retirado do [Machine Learning For Everyone]

Aprendizado supervisionado vs não supervisionado

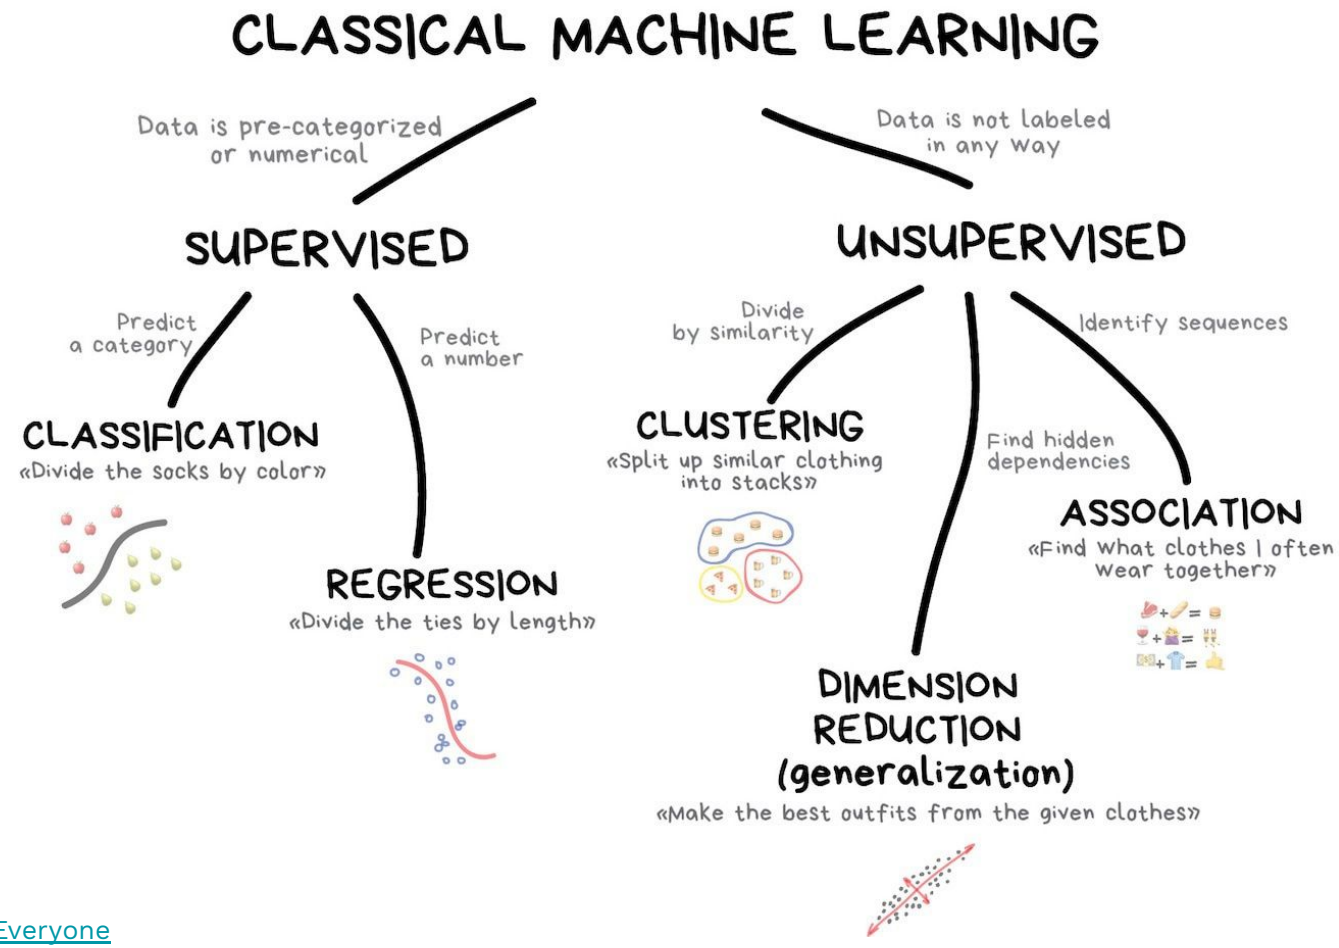


Diagrama retirado do [Machine Learning For Everyone]

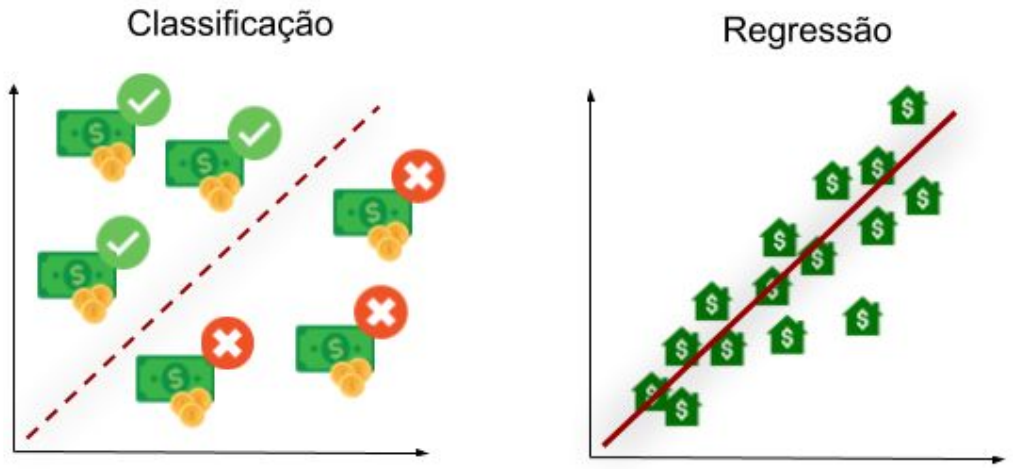
Aprendizado supervisionado e não supervisionado

Aprendizado supervisionado

- Regressão
- Classificação

Aprendizado não supervisionado

- Clustering



Aprendizado supervisionado

Classificação de dados

Na tarefa de classificação, o objetivo é que nosso algoritmo seja capaz de indicar a qual **classe** um exemplo pertence com base em um conjunto de dados já classificado.

Atributos (features) | **Classe (target/label)**

Idade	Renda	Possui dívidas	Cartão de crédito aprovado
18	1000	Não	Não
25	2500	Sim	Sim
50	4500	Sim	Não
42	10000	Não	Não
33	6000	Não	Sim
27	5700	Não	Não

Exemplo



Há diferentes tipos de conjunto de dados...

Conjunto de treinamento é utilizado pelo modelo para aprender

Conjunto de teste é utilizado para avaliar o desempenho do modelo para dados não vistos



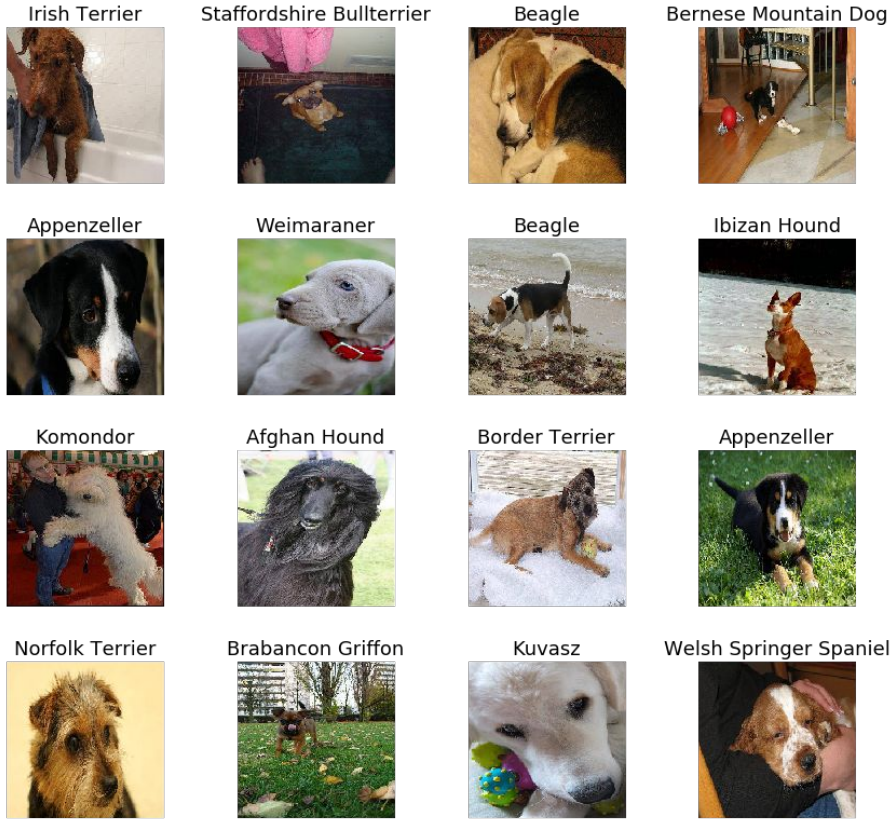
* Pode ainda existir um conjunto de validação, conforme explicado aqui.

Tipos de problemas

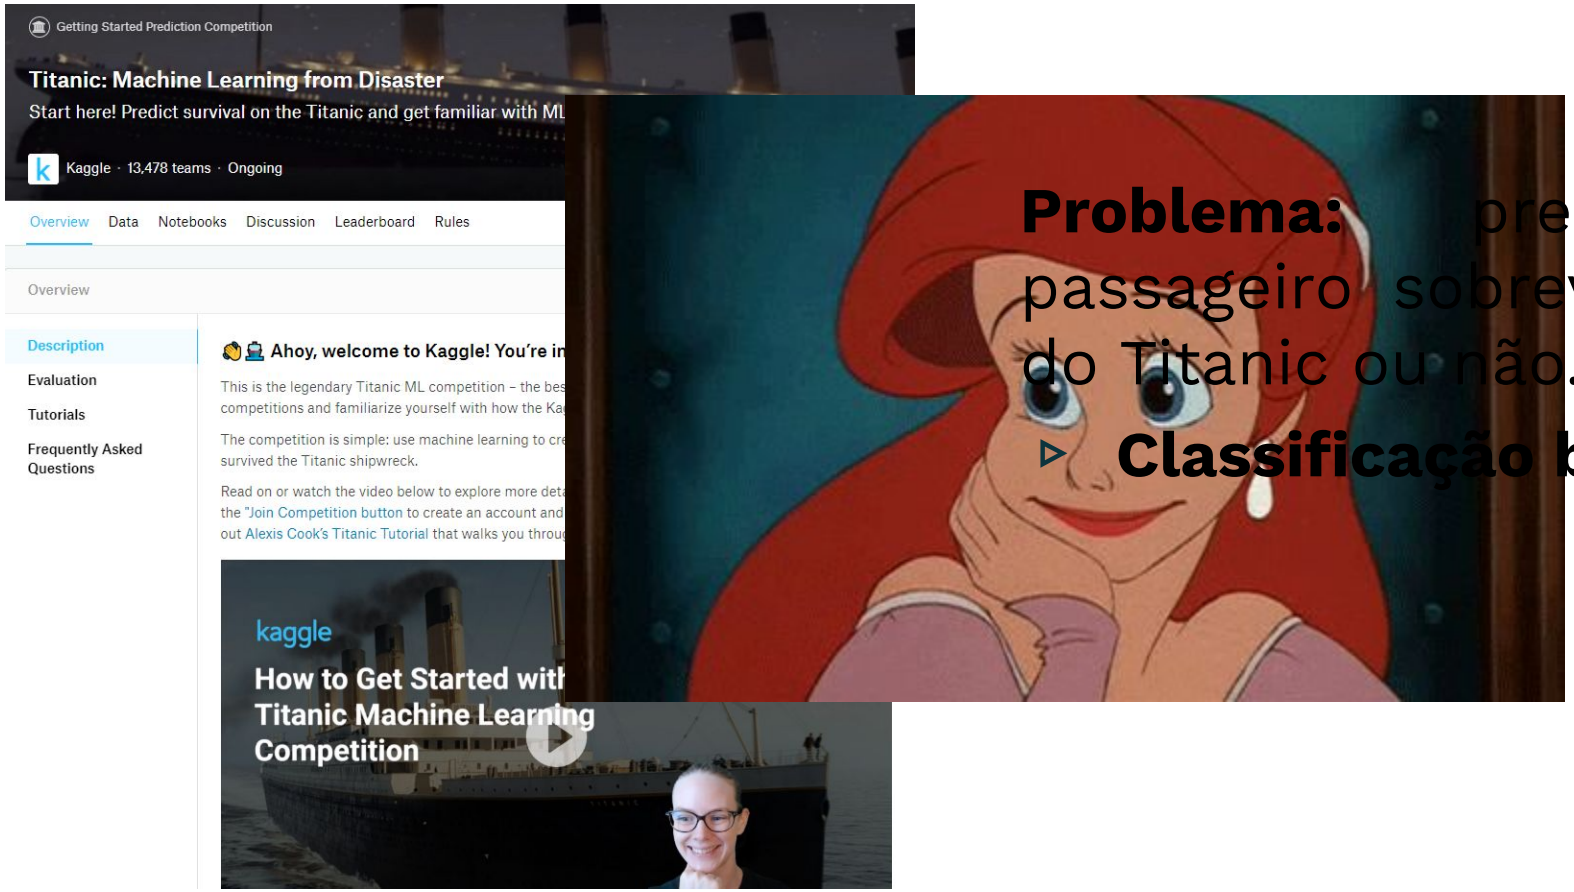
Classificação binária



Classificação multiclasse



Vamos construir nosso primeiro modelo de classificação?



Problema: predizer se um passageiro sobreviveu ao naufrágio do Titanic ou não.

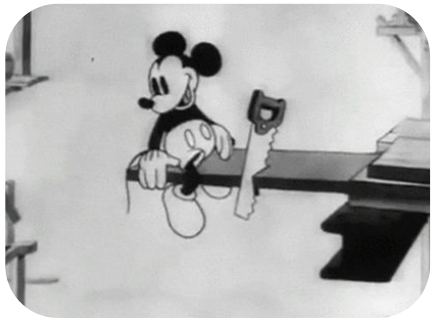
- **Classificação binária**

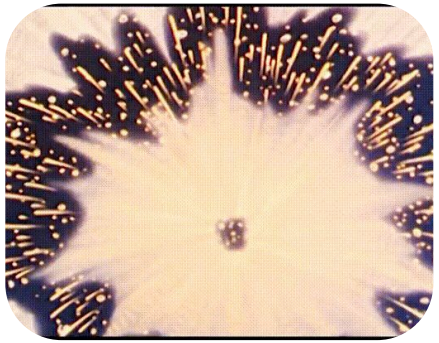
Vamos construir nosso primeiro modelo de classificação?

Seguiremos o seguinte fluxo:

Análise exploratória → **Feature Engineering** → **Modelagem** → **Avaliação**









Pré-processamento dos dados

Pré-processamento dos dados

Essa etapa é **MUITO** importante (e é a que demora mais tempo)!!!
É nela em que iremos preparar o conjunto de dados que será utilizado para treinar o modelo

Análise exploratória

- Entender o conjunto de dados
- Identificar quais atributos fazem sentido
- Identificar atributos que podem ser criados
- Identificar a necessidade de se fazer transformações nos dados

Feature engineering

- Preparar o conjunto de dados de maneira apropriada para o problema e para o algoritmo que será utilizado
- Nela, lidamos com
  - Dados faltantes
  - Outliers
  - Transformações de atributos categóricos
  - Etc.



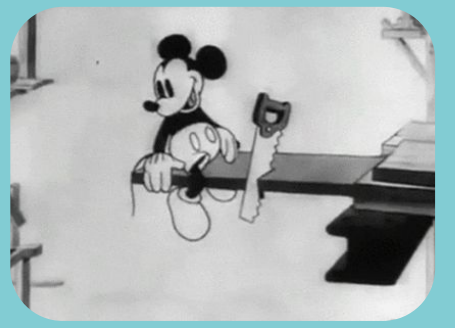
Esse artigo do Medium resume algumas técnicas de Feature Engineering

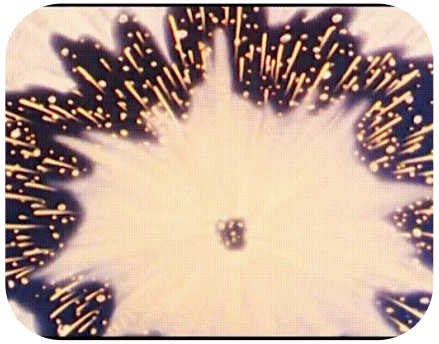

Vamos praticar!

Pré-processamento dos dados concluído! \o/

Análise exploratória → **Feature Engineering** → **Modelagem** → **Avaliação**









Pré-processamento dos dados





Que modelo escolher?

Existem diversos algoritmos de Machine Learning para resolvermos problemas de classificação

Naive Bayes

Redes neurais

Árvore de decisão

KNN

SVM

Regressão logística



O Scikit Learn já tem a implementação de vários desses algoritmos

Árvore de Decisão



Vamos começar com alguns exemplos...



Akinator!



Recomendação de APPs!



Espécies de animais!

Recomendação de apps

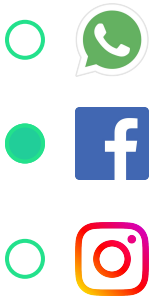
Escolaridade	Faixa etária	Aplicativo
Ensino médio	Idoso	
Ensino superior	Idoso	
Ensino médio	Adulto	
Ensino superior	Adulto	
Ensino superior	Adulto	
Ensino médio	Idoso	
Ensino médio	Adulto	
Ensino médio	Adulto	
Ensino superior	Idoso	
Ensino superior	Adulto	

- Escolaridade
- Faixa etária
- Aplicativo baixado

Recomendação de apps

Escolaridade	Faixa etária	Aplicativo
Ensino médio	Idoso	
Ensino superior	Idoso	
Ensino médio	Adulto	
Ensino superior	Adulto	
Ensino superior	Adulto	
Ensino médio	Idoso	
Ensino médio	Adulto	
Ensino médio	Adulto	
Ensino superior	Idoso	
Ensino superior	Adulto	

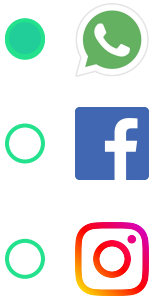
- Uma pessoa adulta com ensino médio completo. Qual aplicativo você recomendaria?



Recomendação de apps

Escolaridade	Faixa etária	Aplicativo
Ensino médio	Idoso	
Ensino superior	Idoso	
Ensino médio	Adulto	
Ensino superior	Adulto	
Ensino superior	Adulto	
Ensino médio	Idoso	
Ensino médio	Adulto	
Ensino médio	Adulto	
Ensino superior	Idoso	
Ensino superior	Adulto	

- Uma pessoa aposentada de 65 anos. Qual aplicativo você recomendaria?



Recomendação de apps

Escolaridade	Faixa etária	Aplicativo
Ensino médio	Idoso	
Ensino superior	Idoso	
Ensino médio	Adulto	
Ensino superior	Adulto	
Ensino superior	Adulto	
Ensino médio	Idoso	
Ensino médio	Adulto	
Ensino médio	Adulto	
Ensino superior	Idoso	
Ensino superior	Adulto	

- Entre faixa etária e escolaridade, qual parece ser mais importante para recomendar um aplicativo?
  - Escolaridade
  - Faixa etária



Recomendação de apps

Escolaridade	Faixa etária	Aplicativo
Ensino médio	Idoso	
Ensino superior	Idoso	
Ensino médio	Adulto	
Ensino superior	Adulto	
Ensino superior	Adulto	
Ensino médio	Idoso	
Ensino médio	Adulto	
Ensino médio	Adulto	
Ensino superior	Idoso	
Ensino superior	Adulto	

- Entre faixa etária e escolaridade, qual parece ser mais importante para recomendar um aplicativo?
  - ○ Escolaridade
  - ○ Faixa etária

Escolaridade	
Ensino Médio	Ensino Superior

Faixa etária	
Adulto	Idoso



Recomendação de apps

Escolaridade	Faixa etária	Aplicativo
Ensino médio	Idoso	
Ensino superior	Idoso	
Ensino médio	Adulto	
Ensino superior	Adulto	
Ensino superior	Adulto	
Ensino médio	Idoso	
Ensino médio	Adulto	
Ensino médio	Adulto	
Ensino superior	Idoso	
Ensino superior	Adulto	

- Entre faixa etária e escolaridade, qual parece ser mais importante para recomendar um aplicativo?
  - ○ Escolaridade
  - ● Faixa etária

Escolaridade	
Ensino Médio	Ensino Superior
	

Faixa etária	
Adulto	Idoso
	



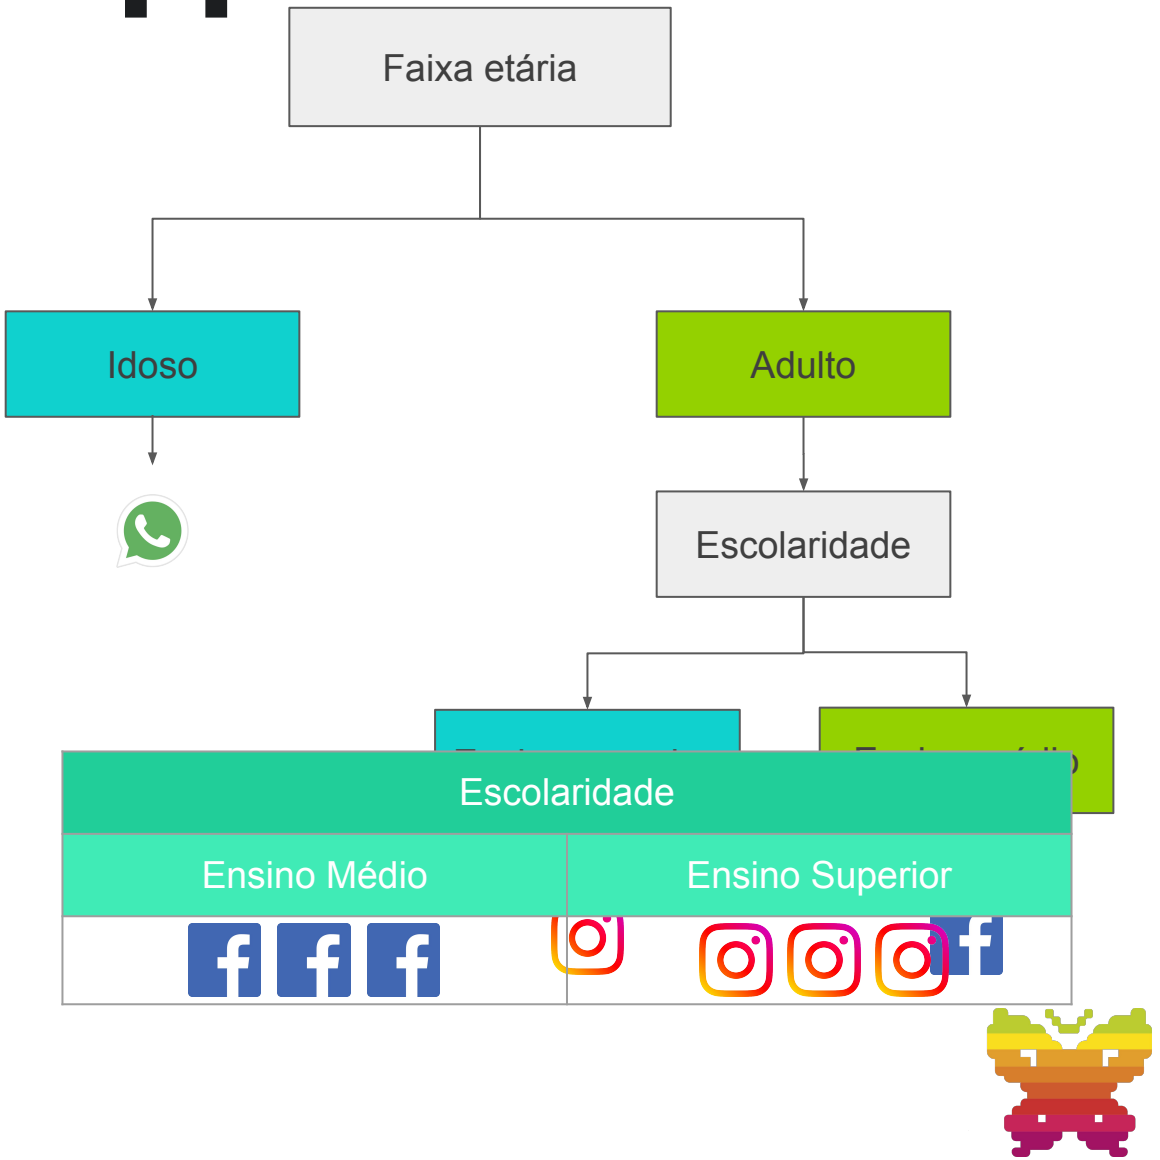
Recomendação de apps

Escolaridade	Faixa etária	Aplicativo
Ensino médio	Idoso	
Ensino superior	Idoso	
Ensino médio	Adulto	
Ensino superior	Adulto	
Ensino superior	Adulto	
Ensino médio	Idoso	
Ensino médio	Adulto	
Ensino médio	Adulto	
Ensino superior	Idoso	
Ensino superior	Adulto	



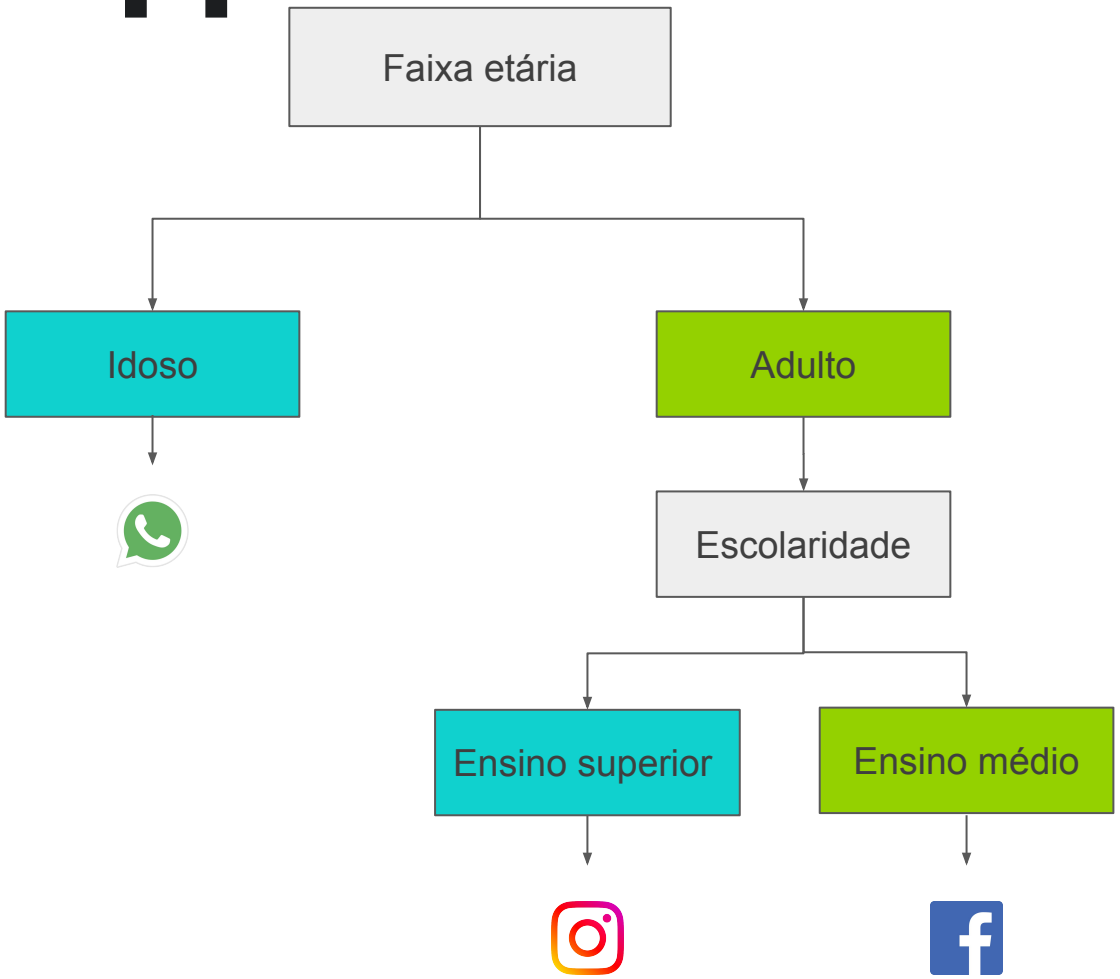
Recomendação de apps

Escolaridade	Faixa etária	Aplicativo
Ensino médio		
Ensino superior		
Ensino superior		
Ensino médio		
Ensino médio		
Ensino superior		



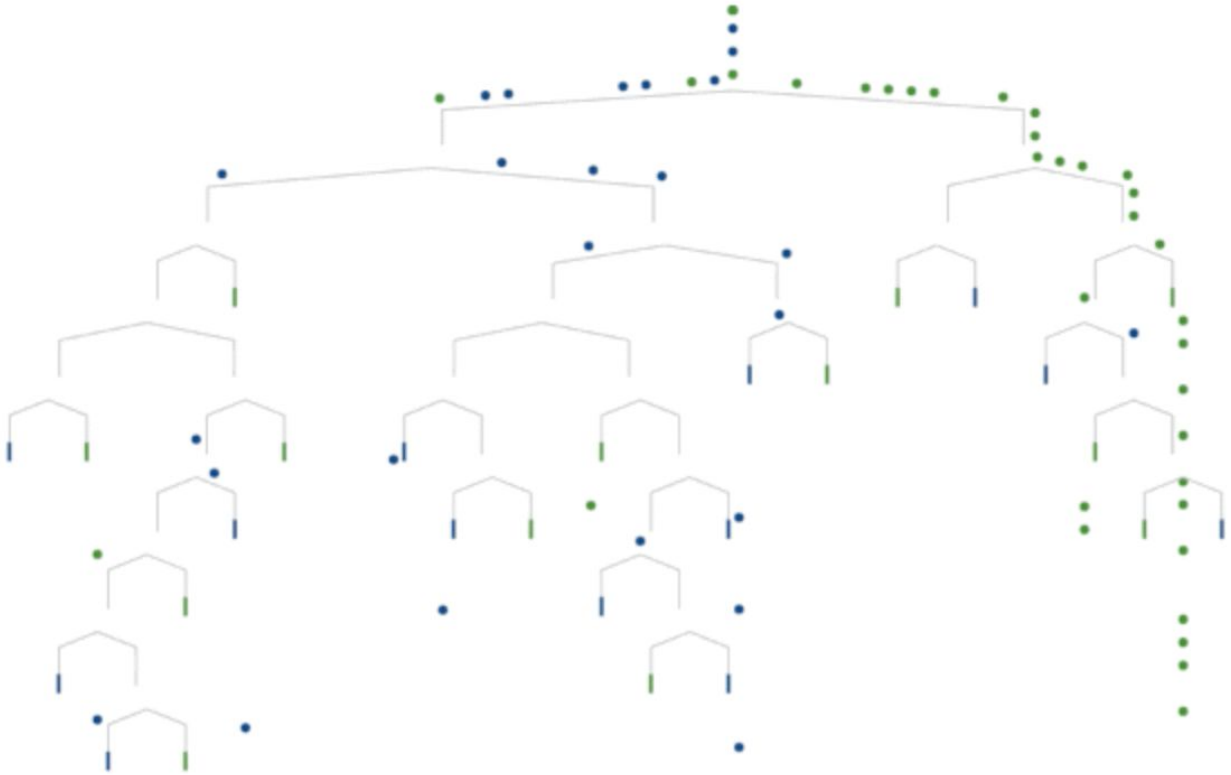
Recomendação de apps

Escolaridade	Faixa etária	Aplicativo
Ensino médio	Idoso	
Ensino superior	Idoso	
Ensino médio	Adulto	
Ensino superior	Adulto	
Ensino superior	Adulto	
Ensino médio	Idoso	
Ensino médio	Adulto	
Ensino médio	Adulto	
Ensino superior	Idoso	
Ensino superior	Adulto	



Mas afinal, o que é árvore de decisão?

É um modelo que busca aprender uma sequência de regras estruturadas em uma árvore a fim de maximizar a separação entre exemplos de diferentes classes



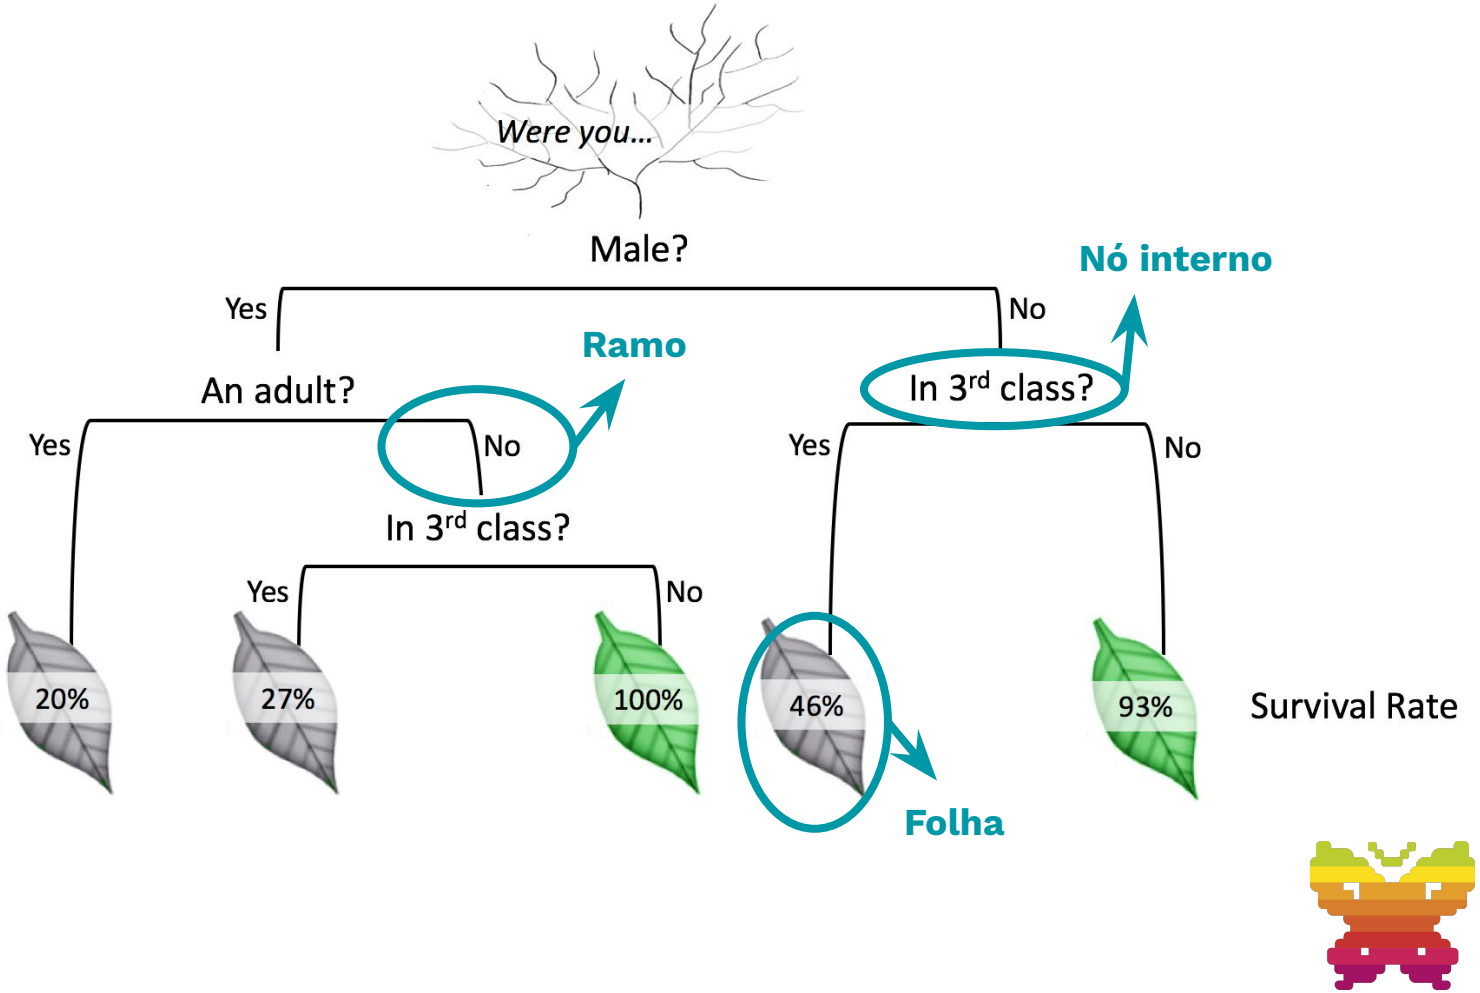
Retiramos esse gif daqui. Nesse link tem um conteúdo mais interativo explicando sobre esse tipo de modelo :)

Mas afinal, o que é árvore de decisão?

- **Nó interno** representa um atributo
- **Ramo** é a decisão sobre um atributo
- **Folha** é o nó final com a classe predita

O treinamento é feito através da construção da árvore.





Legal! E... como eu construo?

Vamos usar mais um exemplo:

Prever quando alguém vai jogar bola!

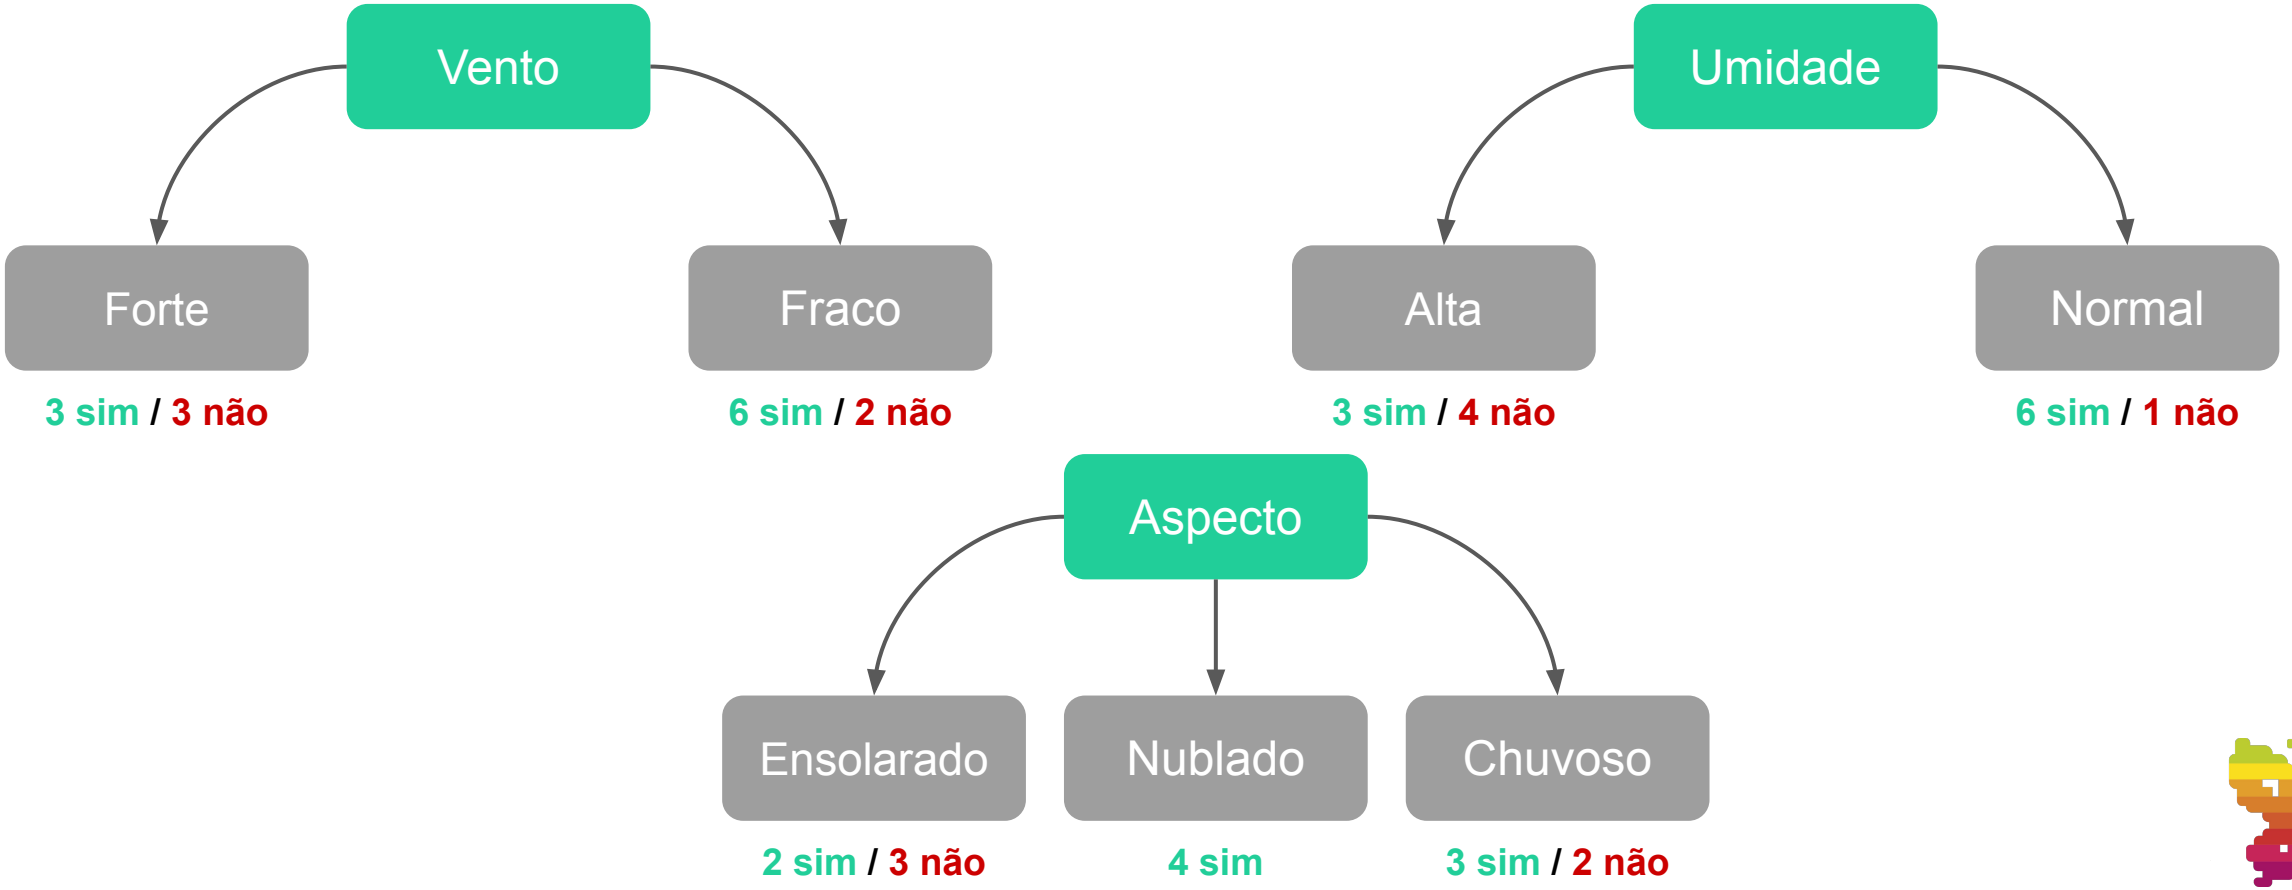


Dia	Aspecto	Umidade	Vento	Jogar?
D1	ensolarado	alta	forte	não
D2	ensolarado	alta	fraco	não
D3	nublado	alta	fraco	sim
D4	chuvoso	alta	fraco	sim
D5	chuvoso	normal	fraco	sim
D6	chuvoso	normal	forte	não
D7	nublado	normal	forte	sim
D8	ensolarado	alta	fraco	não
D9	ensolarado	normal	fraco	sim
D10	chuvoso	normal	fraco	sim
D11	ensolarado	normal	forte	sim
D12	nublado	alta	forte	sim
D13	nublado	normal	fraco	sim
D14	chuvoso	alta	forte	não



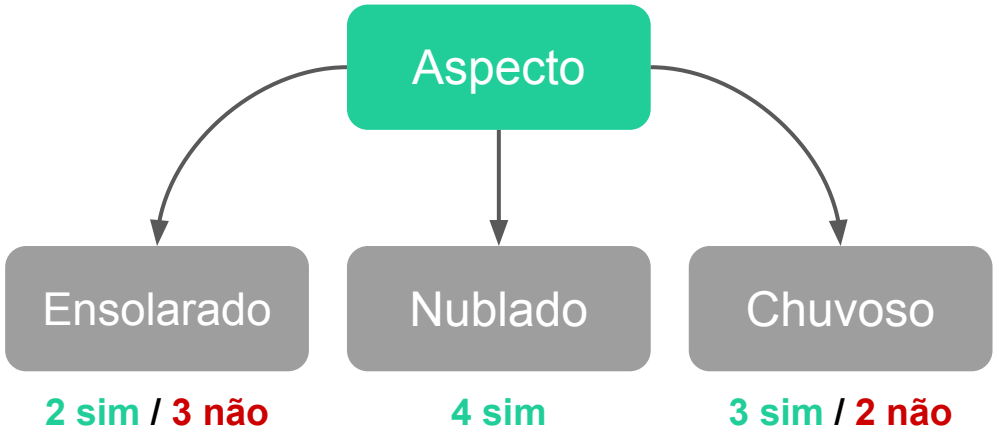
Escolhendo atributos

Por qual atributo devemos começar a nossa árvore?



Escolhendo atributos

O melhor atributo é aquele que discrimina melhor a nossa variável resposta (Jogar)



O atributo Aspecto representa um **ganho de informação** maior!



Entropia

Como fazemos pra escolher o melhor atributo sistematicamente?

Vamos usar a **entropia** dos subconjuntos como métrica de **impureza**!





nede quão “bagunçado” é um

dados!

alta = dados misturados

baixa = dados separados

Entropia - Cálculo

$$H(E) = -P_{yes} \log_2 P_{yes} - P_{no} \log_2 P_{no}$$

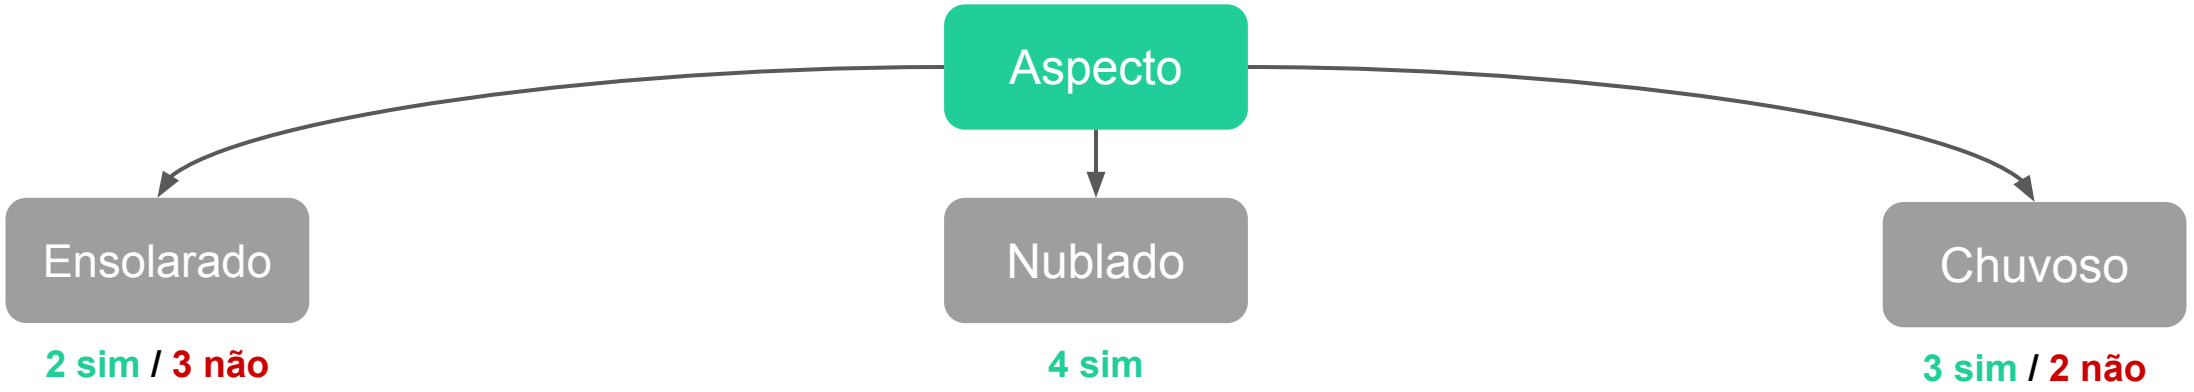
$$P_{yes} = \frac{n_{yes}}{n_{yes} + n_{no}}$$

$$P_{no} = \frac{n_{no}}{n_{yes} + n_{no}}$$



Entropia - Exemplo

$$H(E) = -P_{yes} \log_2 P_{yes} - P_{no} \log_2 P_{no}$$



$$H(E_S) = -\frac{2}{5}\log_2\frac{2}{5} - \frac{3}{5}\log_2\frac{3}{5}$$
$$= -0.4\log_2 0.4 - 0.6\log_2 0.6$$
$$= 0.9705$$

$$H(E_O) = -\frac{4}{4}\log_2\frac{4}{4} - \frac{0}{4}\log_2\frac{0}{4}$$
$$= -1\log_2 1 - 0\log_2 0$$
$$= 0.0$$

$$H(E_R) = -\frac{3}{5}\log_2\frac{3}{5} - \frac{2}{5}\log_2\frac{2}{5}$$
$$= -0.6\log_2 0.6 - 0.4\log_2 0.4$$
$$= 0.9705$$



Entropia Esperada

- Esse cálculo mostra a entropia de cada subgrupo formato pela divisão do atributo **aspecto;**
- Como calcular a entropia esperada de cada atributo?
- Considere uma divisão **S** em um atributo com **K** valores diferentes, que divide o conjunto **E**, de tamanho **N**, em subconjuntos $\mathbf{E_1}$, $\mathbf{E_2}$, $\mathbf{E_3}$... $\mathbf{E_k}$ de tamanhos $\mathbf{N_1}$, $\mathbf{N_2}$, $\mathbf{N_3}$... $\mathbf{N_k}$, respectivamente.

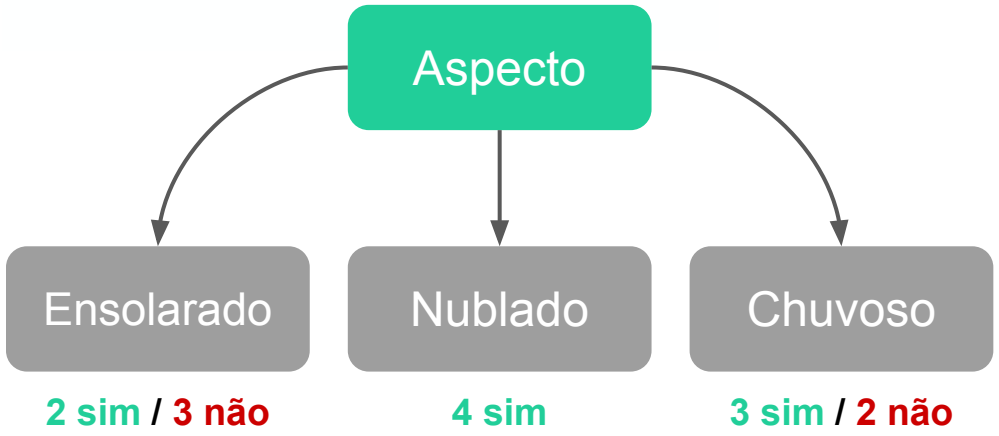
$$EH(S) = \sum_{i=1}^{K} \frac{N_i}{N} H(E_i)$$

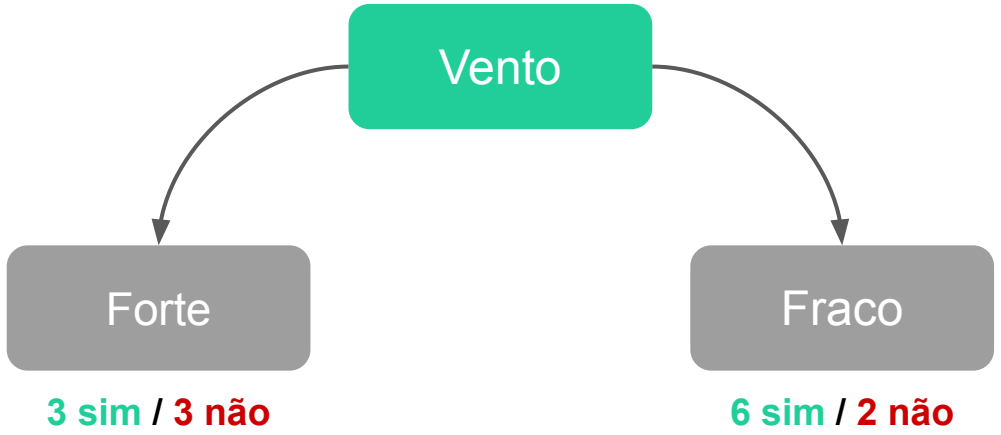
- No nosso exemplo:
  - S = atributo aspecto
  - K = 3 (ensolarado, nublado, chuvoso)
  - E = conjunto de dados de tamanho N=14
  - H(E_i) = entropia calculada de cada subconjunto



Entropia Esperada - Exemplo

$$EH(S) = \sum_{i=1}^{K} \frac{N_i}{N} H(E_i)$$





$$EH(S_{Aspecto}) = \frac{5}{14}0.9705 + \frac{4}{14}0 + \frac{5}{14}0.9705 = 0.6932$$

$$EH(S_{Vento}) = \frac{6}{14}1 + \frac{8}{14}0.8112 = 0.8921$$

Ganho de informação

Queremos **reduzir a entropia**, para **aumentar o ganho de informação**!

- Entropia alta = dados misturados = menor ganho de informação
- Entropia baixa = dados separados = maior ganho de informação







Ganho de informação - Cálculo

Dia	Aspecto	Umidade	Vento	Jogar?
D1	ensolarado	alta	forte	não
D2	ensolarado	alta	fraco	não
D3	nublado	alta	fraco	sim
D4	chuvoso	alta	fraco	sim
D5	chuvoso	normal	fraco	sim
D6	chuvoso	normal	forte	não
D7	nublado	normal	forte	sim
D8	ensolarado	alta	fraco	não
D9	ensolarado	normal	fraco	sim
D10	chuvoso	normal	fraco	sim
D11	ensolarado	normal	forte	sim
D12	nublado	alta	forte	sim
D13	nublado	normal	fraco	sim
D14	chuvoso	alta	forte	não

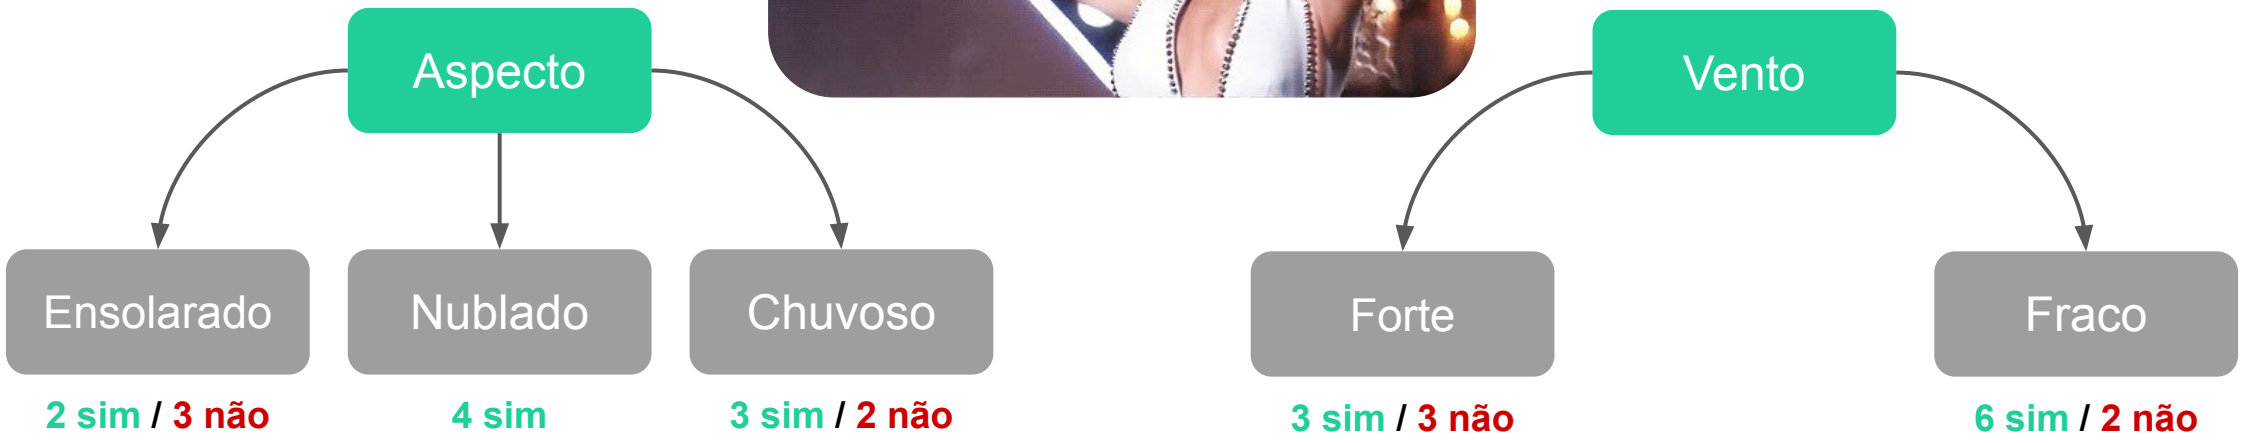
$$I(S) = H(E) - EH(S)$$

Onde **H(E)** é a entropia geral do conjunto, considerando subgrupos $\mathbf{E_i}$ como as instâncias de cada classe (9 sim / 5 não).



Ganho de informação - Cálculo

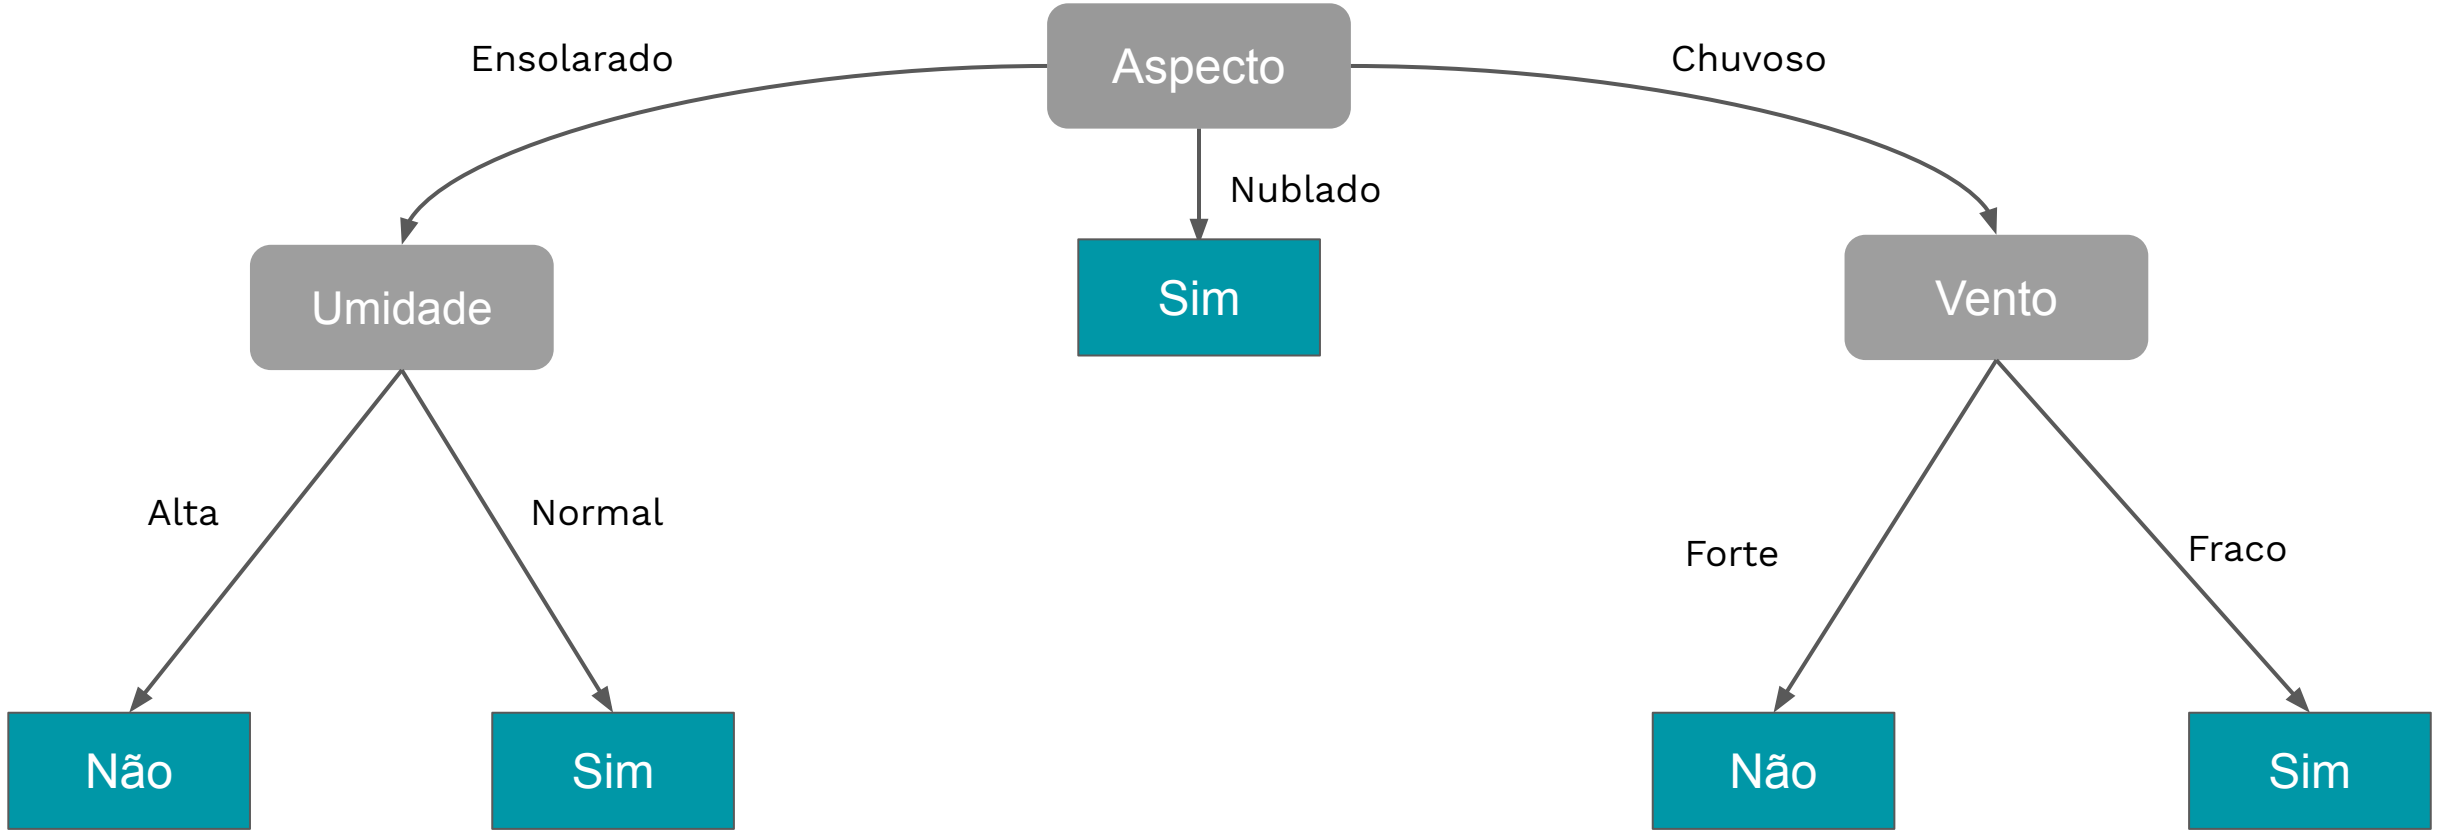
$H(E$  0.357



$$I(S_{Aspecto}) = 0.9402 - 0.6932 = 0.2470$$

$$I(S_{Vento}) = 0.9402 - 0.8921 = 0.0482$$

Após todos os cálculos, essa seria a nossa árvore final:



Quais são as vantagens da árvore de decisão?

- Fácil de explicar e interpretar
- Pouco esforço na etapa de pré-processamento
- Pouco complexas computacionalmente
- Serve para problemas de classificação multiclasse
- Serve tanto para problemas de classificação quanto regressão



E quais são as desvantagens?

- Fácil de ocorrer overfitting
- Instáveis
- Não garante a melhor construção possível




Vamos praticar!

UHUL! Fizemos nosso primeiro modelo de classificação



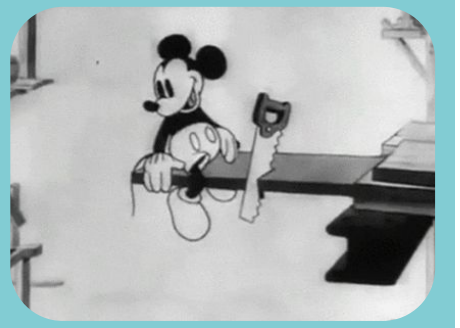


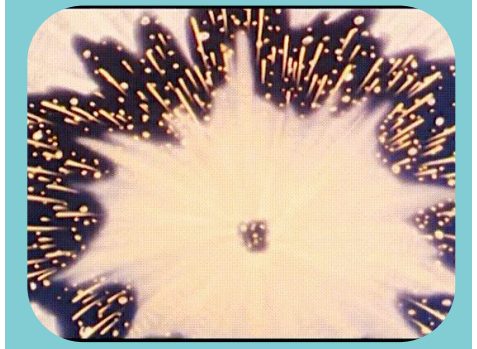
...Mas como sabemos se nosso modelo está bom?

Precisamos avaliar nosso modelo!

Análise exploratória → **Feature Engineering** → **Modelagem** → **Avaliação**









Pré-processamento dos dados







No caso do desafio do Titanic, a métrica de avaliação é a ACURÁCIA

Acurácia é a proporção de exemplos que foram preditos corretamente pelo modelo

Vamos submeter nosso modelo e ver a sua acurácia?



Nem sempre a acurácia é a melhor métrica de avaliação...

Vamos supor que tenhamos que resolver um problema de classificação que fosse **desbalanceado**

O problema seria predizer se uma transação seria fraudulenta ou não. Vamos supor que a proporção de fraudes seja de 3%...

...Se o modelo chutasse todos os exemplos como pertencentes a classe majoritária (não é fraude), teríamos uma **acurácia de 97%**!

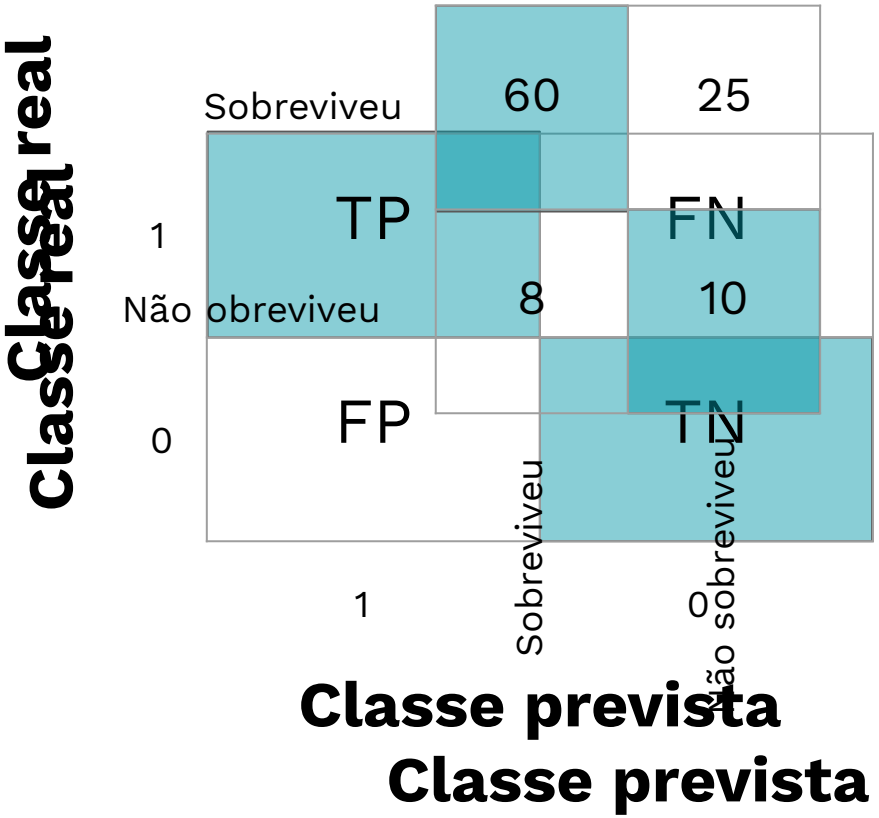
Vocês acham que esse é um bom modelo?



Quais outras métricas de avaliação podemos usar?



Matriz de confusão



TP (True Positive): são os exemplos que eram da classe positiva e o modelo predisse corretamente

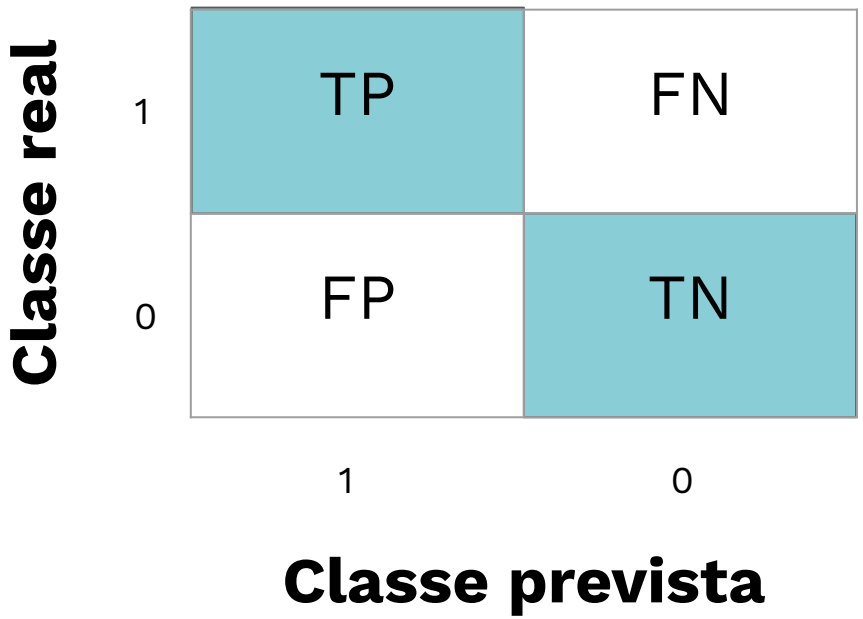
TN (True Negative): são os exemplos que eram da classe negativa e o modelo predisse corretamente

FN (False Negative): são os exemplos que eram da classe negativa, mas o modelo predisse quem era da classe positiva

FP (False Positive): são os exemplos que eram da classe positiva, mas o modelo predisse quem era da classe negativa

Quais outras métricas de avaliação podemos usar?

O legal da matriz de confusão é que, a partir dela, podemos tirar outras métricas como...



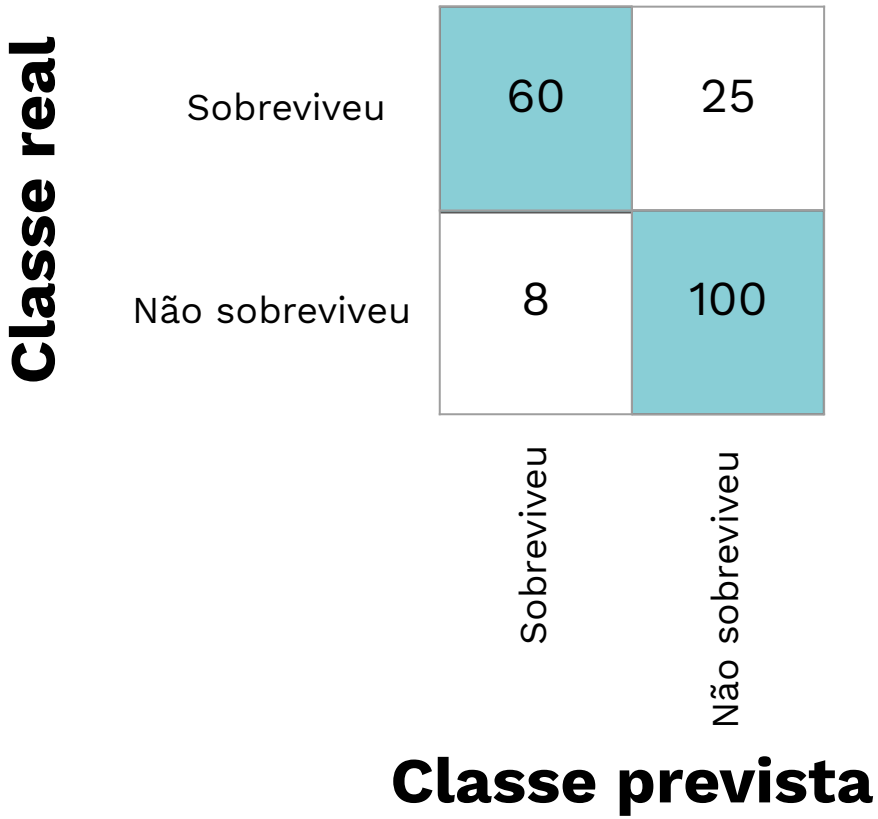
Acurácia

De todas as predições que o modelo fez, quantos ele acertou?

$$\frac{TP + TN}{TP + FP + FN + TN}$$

Quais outras métricas de avaliação podemos usar?

O legal da matriz de confusão é que, a partir dela, podemos tirar outras métricas como...



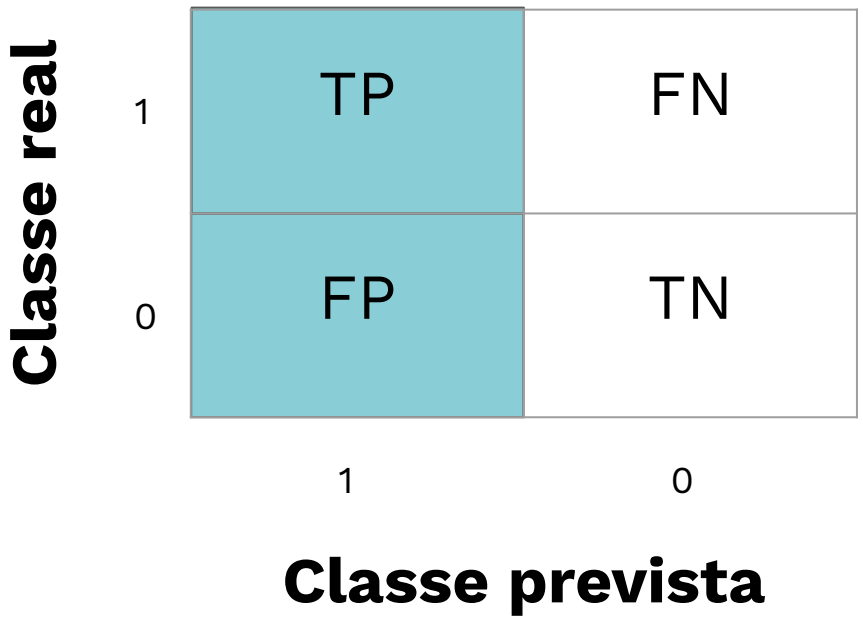
Acurácia

De todas as predições que o modelo fez, quantos ele acertou?

$$\frac{60 + 100}{100 + 8 + 25 + 60} = 0.829$$

Quais outras métricas de avaliação podemos usar?

O legal da matriz de confusão é que, a partir dela, podemos tirar outras métricas como...



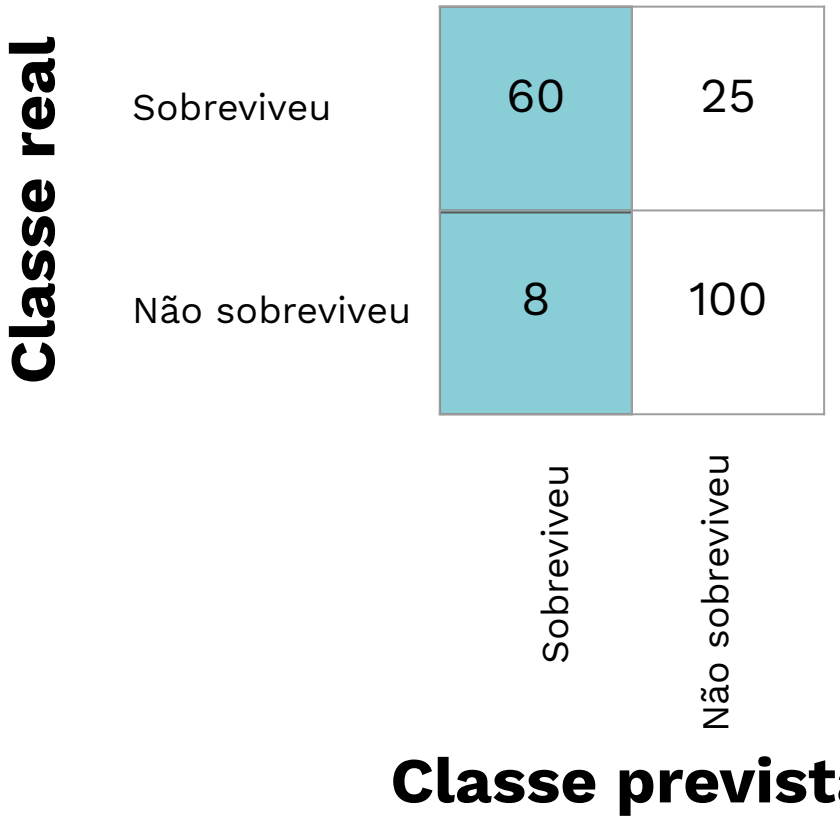
Precisão

De todas os exemplos que o modelo classificou como sendo da classe positiva, quais realmente eram?

$$\frac{TP}{TP + FP}$$

Quais outras métricas de avaliação podemos usar?

O legal da matriz de confusão é que, a partir dela, podemos tirar outras métricas como...



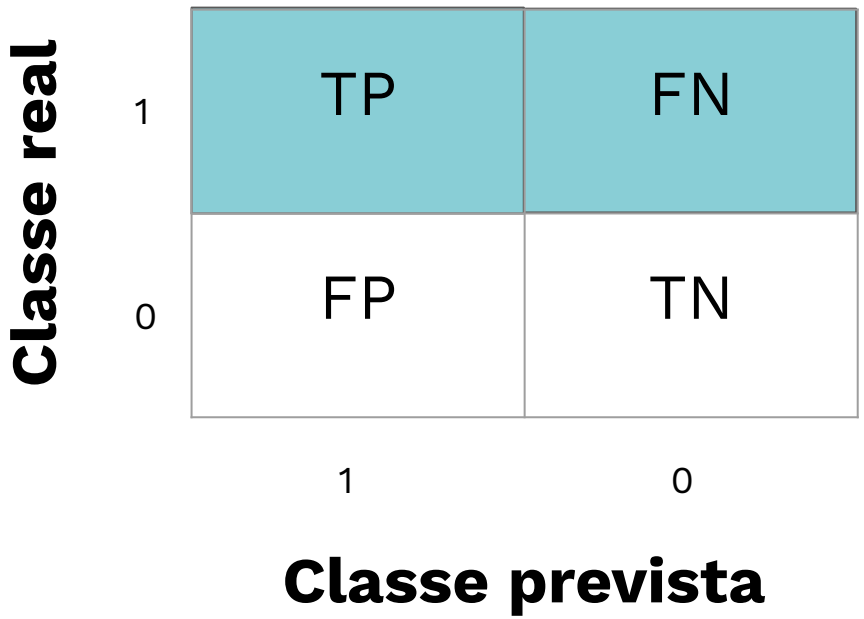
Precisão

De todas os exemplos que o modelo classificou como sendo da classe positiva, quais realmente eram?

$$\frac{60}{60 + 8} = 0.882$$

Quais outras métricas de avaliação podemos usar?

O legal da matriz de confusão é que, a partir dela, podemos tirar outras métricas como...



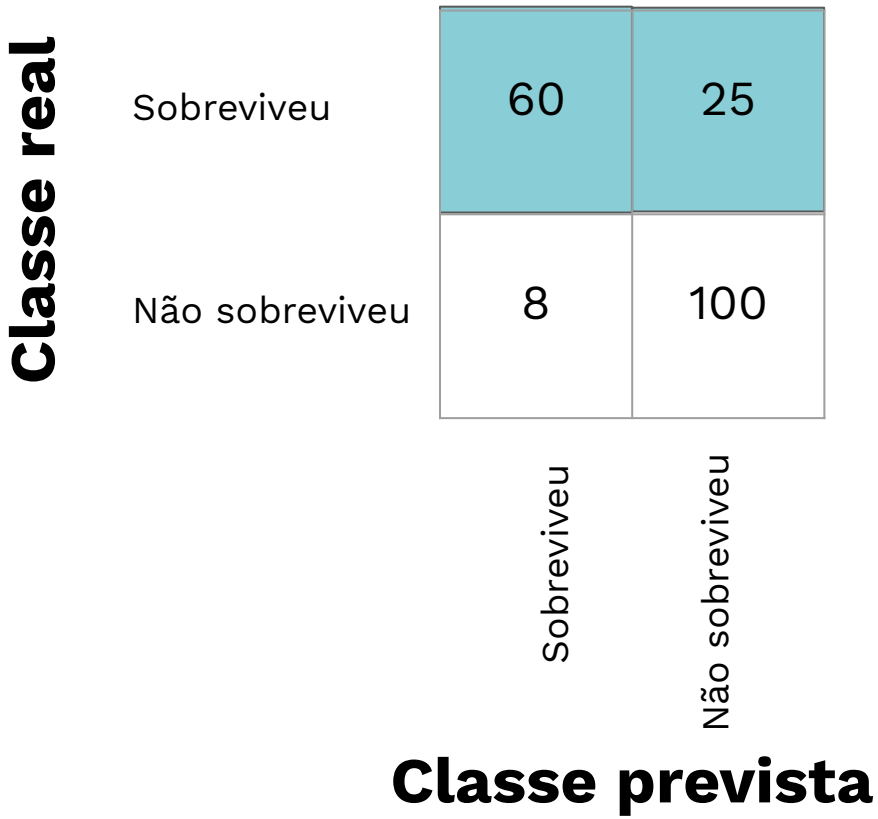
Recall (sensibilidade)

De todos os exemplos da classe positiva, quantos o modelo classificou corretamente?

$$\frac{TP}{TP + FN}$$

Quais outras métricas de avaliação podemos usar?

O legal da matriz de confusão é que, a partir dela, podemos tirar outras métricas como...



Recall (sensibilidade)

De todos os exemplos da classe positiva, quantos o modelo classificou corretamente?

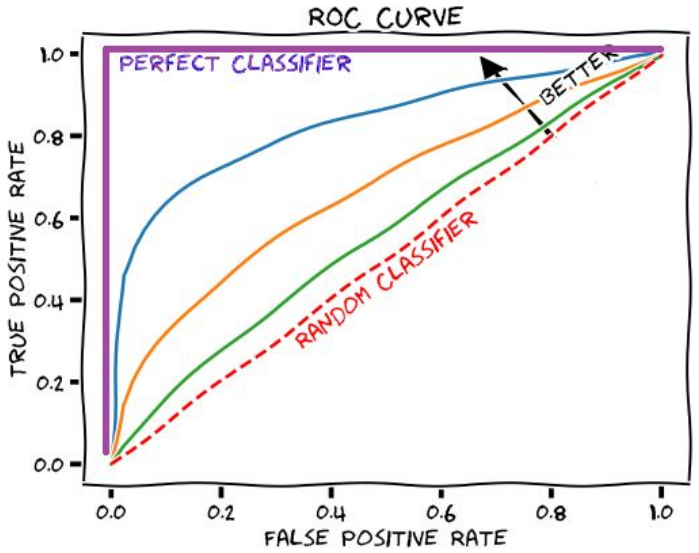
$$\frac{60}{60 + 25} = 0.705$$

Aqui tem artigo falando sobre a questão do recall vs precisão

Quais outras métricas de avaliação podemos usar?

A partir dessas métricas que mencionamos, podemos criar várias outras...

ROC AUC



Aqui tem um resumo sobre isso

F1-score

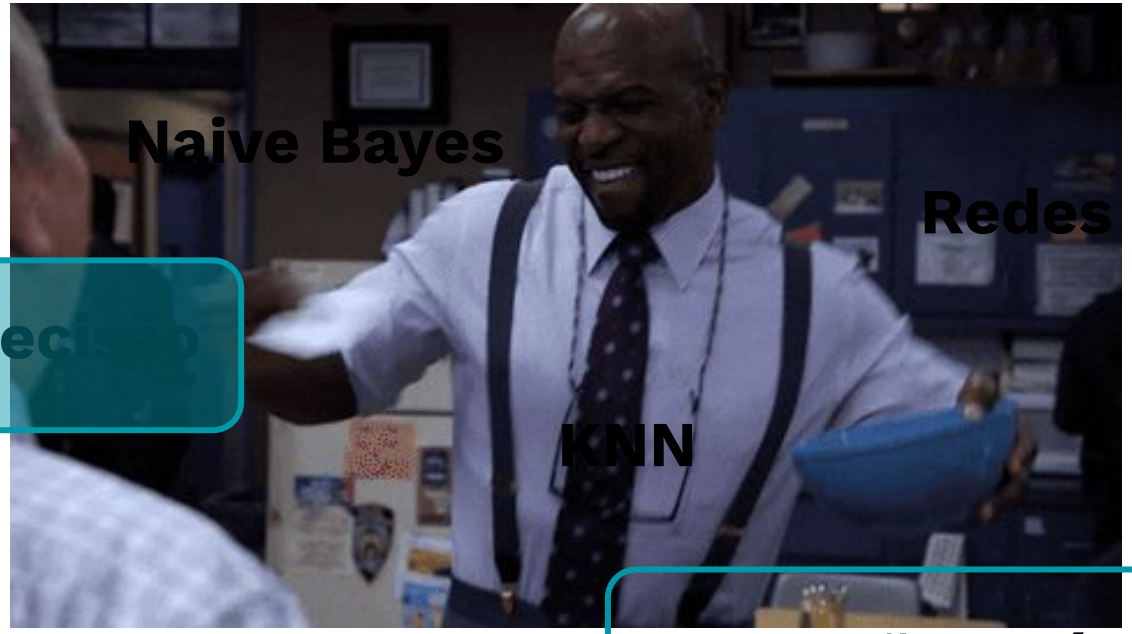
$$\frac{2 * (\text{Recall} * \text{Precisão})}{(\text{Recall} + \text{Precisão})}$$

E aqui tem um resumo sobre o F1-score e as métricas que a gente viu anteriormente




Vamos praticar!

Vamos ver mais um modelo de classificação?



Regressão logística

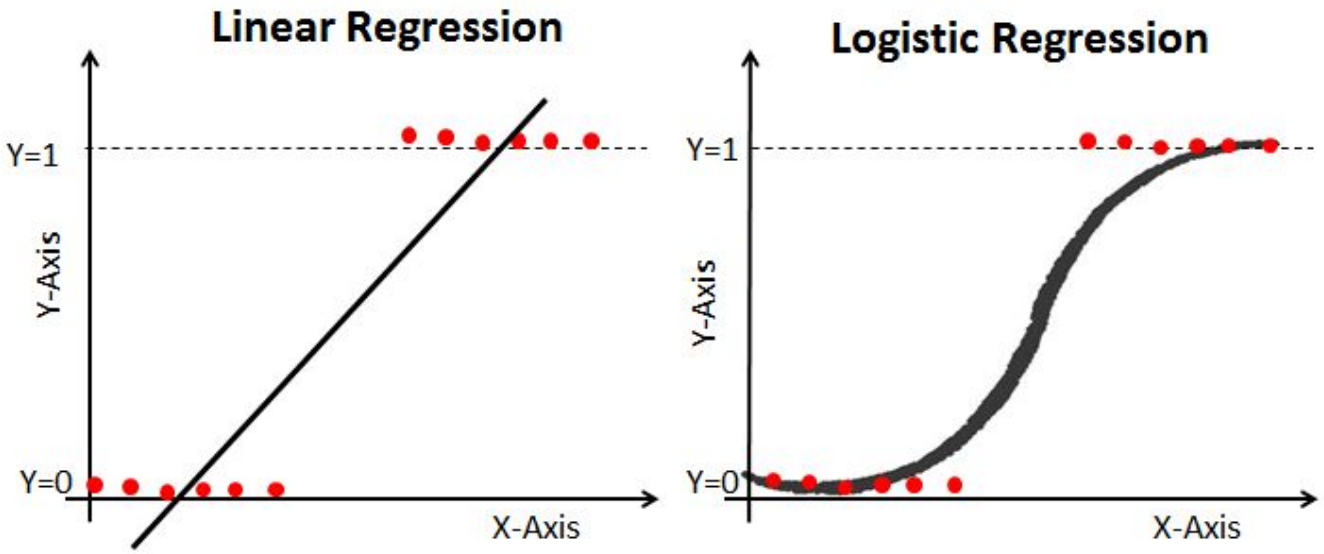


Espera, **regressão** logística é um modelo de classificação?

Pois é...É um modelo de **classificação binária**!



E como a regressão logística funciona?



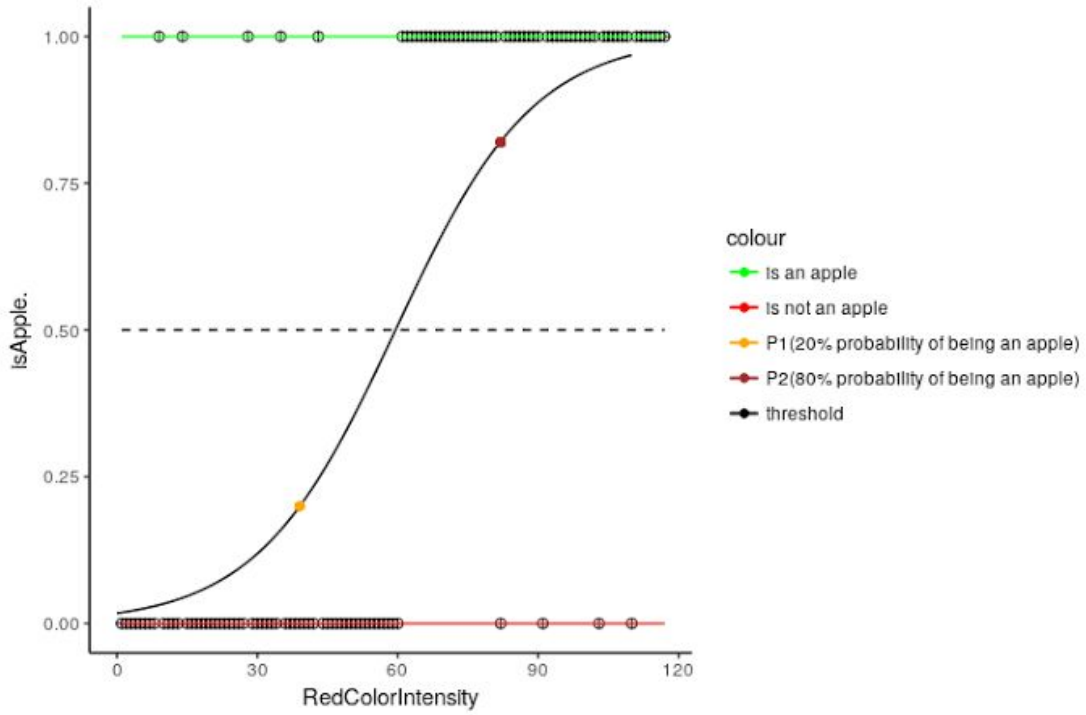
$$y = \beta 0 + \beta 1X1 + \beta 2X2 + \ldots\ldots + \beta nXn$$

$$p = 1/1 + e^{-y}$$

$$p = 1/1 + e^{-(\beta 0 + \beta 1X1 + \beta 2X2 \ldots\ldots \beta nXn)}$$

E como a regressão logística funciona?

- Tenta encontrar uma curva para separar os exemplos de classes diferentes
- A curva é ajustada utilizando uma função logística
- Calcula a probabilidade de um exemplo ser 0 ou 1 (no nosso desafio, se o passageiro sobreviveu ou não ao naufrágio do Titanic)



Aqui tem um exemplo de uma regressão logística para o desafio do Titanic

E aqui tem uma explicação um pouco mais aprofundada sobre a matemática por trás

Qual a probabilidade do Jack sobreviver ao naufrágio?

$I_{feminino} = 0$
$I_{2classe} = 0$
$I_{1classe} = 0$
$Idade = 20$

$$y = -1{,}33 + (2{,}55 * I_{feminino}) + (1{,}27 * I_{2classe}) + (2{,}58 * I_{1classe}) - (0{,}04 * Idade)$$

$$y = -1{,}33 + (2{,}55 * 0) + (1{,}27 * 0) + (2{,}58 * 0) - (0{,}04 * 20)$$

$$y = -2{,}13$$

$$p_{Jack} = \frac{1}{1 + e^{-y}} = \frac{1}{1 + e^{-(-2{,}13)}}$$

$$p_{Jack} = 0.106$$



E da Rose?

$I_{feminino} = 1$
$I_{2classe} = 0$
$I_{1classe} = 1$
$Idade = 17$

$$y = -1,33 + (2,55*I_{feminino}) + (1,27*I_{2classe}) + (2,58*I_{1classe}) - (0,04*Idade)$$

$$y = -1,33 + (2,55*1) + (1,27*0) + (2,58*1) - (0,04*17)$$

$$y = 3,12$$

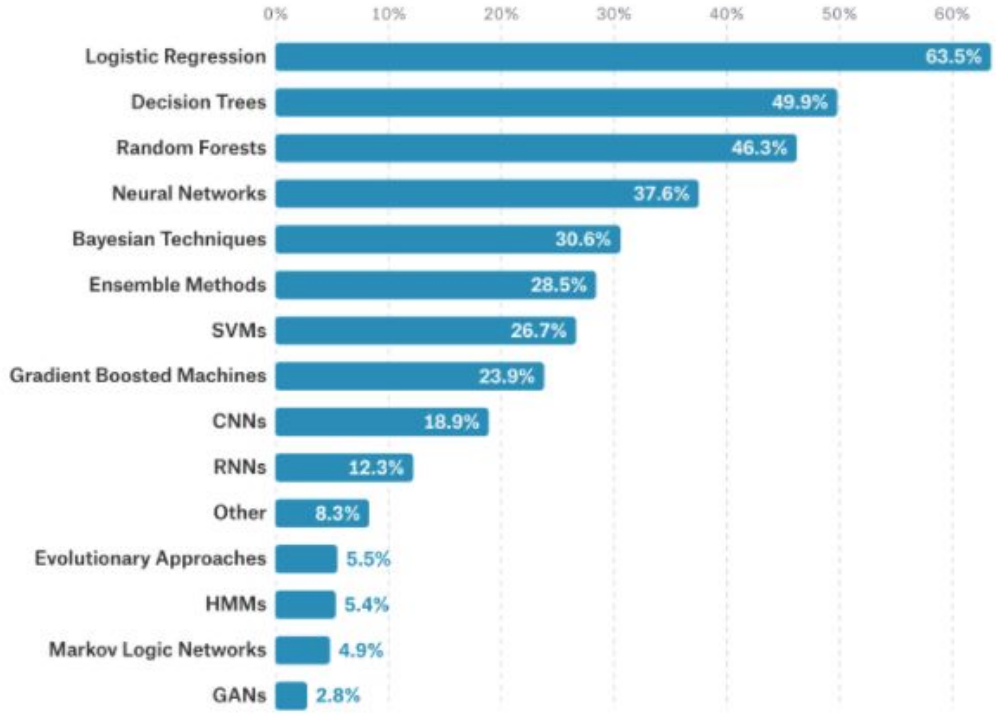
$$p_{Rose} = \frac{1}{1 + e^{-y}} = \frac{1}{1 + e^{-3,12}}$$

$$p_{Rose} = 0.957$$



Aqui tem a implementação logística do Sklearn para vocês brincarem :D

A regressão logística é um dos modelos mais utilizados porque...

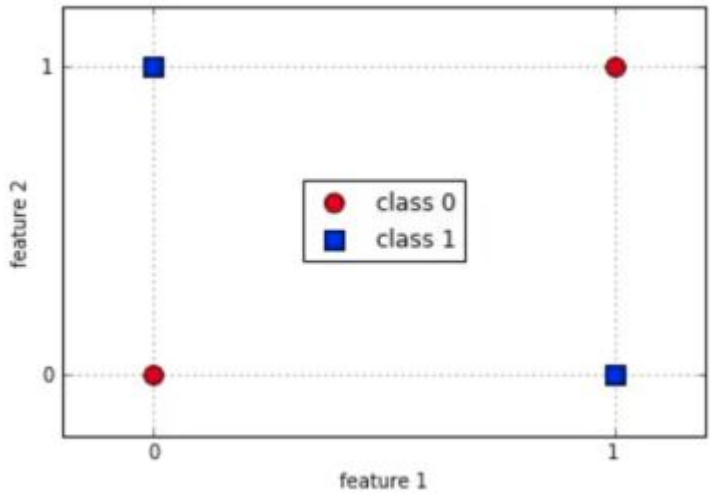


- É um modelo simples de ser implementado
- Geralmente é eficiente
- Retorna uma probabilidade

De acordo com pesquisa realizada pelo Kaggle em 2017

Quais são suas desvantagens?

- É necessário tomar cuidado com features correlacionadas
- Performa mal com problemas não linearmente separáveis





Por hoje, é isso!

No próximo sábado iremos continuar vendo modelos de classificação (e também veremos clustering) \o/

... Por isso é legal vocês estudarem um pouquinho durante a semana porque vamos utilizar muitas coisas na próxima aula ;)



Vamos preencher o formulário de feedback???



http://bit.ly/bootcamp-ds-sp-feedback-19



Obrigada!

Dúvidas?
Podem nos procurar! :D

